курс «Глубокое обучение»

Анализ текстов

Александр Дьяконов

28 марта 2022 года

План

Задачи с текстами, данные, понимания языка (Language Understanding)

Свёрточные модели для текста

Dynamic CNN, VD-CNN, Сравнение CNN vs RNN, C-LSTM

Модель seq2seq, обобщение

Механизм внимания, виды

Области исследований

NLP – всё, что связано с обработкой текстов

NLU – всё, что связано с пониманием текстов (текст $\rightarrow$ действие / ...)

NLG – всё что связано с генерацией текста (... $\rightarrow$ текст)

Задачи с текстами

текст → метка (классификация)

определение темы / настроения / автора

определение тональности

текст → метки (тегирование)

определение тегов

разметка на части речи

текст → текст (seq2seq)

машинный перевод

аннотирование

чат-бот

продолжение текста

генерация по контенту

текст, текст → текст

ответы на вопросы

справочная / экспертная система

… → текст

описание изображения

моделирование / генерация языка

текст → …

parse tree по предложению

генерация объектов по описанию

Термины

токен – элемент последовательности (слово, несколько букв)

словарь – множество допустимых токенов (модель принимает/генерирует только их)

все перечисленные задачи с текстами (кроме последней) – классификация

классов может быть очень много = число всех токенов

Проблемы

0) текст – сигнал (к счастью, дискретный) с разделителями (например, пробелами между словами)

1) один и тот же смысл передаётся по-разному / синонимы

- haha
- hahahahahahahaha
- haaaahaaaa
- lol
- rotflmao
- lol!!!!!!!!!!!!!!
- wow that is big
- that is biiiiiig
- that. is. big.
- waaaaaaay big

2) многозначность / омонимы

«Эти типы стали есть в цехе»

Проблемы

3) динамичность языка, новые слова, сленг

е-комерция, айпадный, зафрендить и т.п.

4) устойчивые выражения, профессиональный сленг, контекст

«бабье лето», «на эпсилон старше меня»

«Петя увидел Васю, неудивительно, **он** был очень зоркий/заметный»

5) разметка, как правило, ручная

6) при попытках признаковой постановки
большие разреженные пространства

7) текст больше чем последовательность предложений

контекст, порядок изложения, расстановка акцентов

История NLP

- предобработка (регулярки, стемминг, лемматизация)
- мешок слов (нормировки), N-граммные модели
- векторные представления слов
- языковые модели
- трансферное обучение (перенос обучения)
- мультиязычность
- мультимодальность
- графы знаний

Данные – есть много открытых данных https://arxiv.org/pdf/2003.01200.pdf

Task	Dataset	Link
Machine Translation	WMT 2014 EN-DE WMT 2014 EN-FR	http://www-lium.univ-lemans.fr/~schwenk/cslm_joint_paper/
Text Summarization	CNN/DM Newsroom DUC Gigaword	https://cs.nyu.edu/~kcho/DMQA/ https://summari.es/ https://www-nlpir.nist.gov/projects/duc/data.html https://catalog.ldc.upenn.edu/LDC2012T21
Reading Comprehension Question Answering Question Generation	ARC CliCR CNN/DM NewsQA RACE SQuAD Story Cloze Test NarativeQA Quasar SearchQA	http://data.allenai.org/arc/ http://aclweb.org/anthology/N18-1140 https://cs.nyu.edu/~kcho/DMQA/ https://datasets.maluuba.com/NewsQA http://www.qizhexie.com/data/RACE_leaderboard https://rajpurkar.github.io/SQuAD-explorer/ http://aclweb.org/anthology/W17-0906.pdf https://github.com/deepmind/narrativeqa https://github.com/bdhingra/quasar https://github.com/nyu-dl/SearchQA
Semantic Parsing	AMR parsing ATIS (SQL Parsing) WikiSQL (SQL Parsing)	https://amr.isi.edu/index.html https://github.com/jkkummerfeld/text2sql-data/tree/master/data https://github.com/salesforce/WikiSQL
Sentiment Analysis	IMDB Reviews SST Yelp Reviews Subjectivity Dataset	http://ai.stanford.edu/~amaas/data/sentiment/ https://nlp.stanford.edu/sentiment/index.html https://www.yelp.com/dataset/challenge http://www.cs.cornell.edu/people/pabo/movie-review-data/
Text Classification	AG News DBpedia TREC 20 NewsGroup	http://www.di.unipi.it/~gulli/AG_corpus_of_news_articles.html https://wiki.dbpedia.org/Datasets https://trec.nist.gov/data.html http://qwone.com/~jason/20Newsgroups/
Natural Language Inference	SNLI Corpus MultiNLI SciTail	https://nlp.stanford.edu/projects/snli/ https://www.nyu.edu/projects/bowman/multinli/ http://data.allenai.org/scitail/
Semantic Role Labeling	Proposition Bank OneNotes	http://propbank.github.io/ https://catalog.ldc.upenn.edu/LDC2013T19

IR-based QA

Stanford Question Answering Dataset (SQuAD) / SQuAD2.0

https://rajpurkar.github.io/SQuAD-explorer/

NewsQA

WikiQA

CuratedTREC

WebQuestions

WikiMovies

Russian: SberQUAD

IR-based QA

Dataset	Example	Article / Paragraph
SQuAD	**Q**: How many provinces did the Ottoman empire contain in the 17th century? **A**: 32	**Article**: Ottoman Empire **Paragraph**: ... At the beginning of the 17th century the empire contained 32 provinces and numerous vassal states. Some of these were later absorbed into the Ottoman Empire, while others were granted various types of autonomy during the course of centuries.
CuratedTREC	**Q**: What U.S. state's motto is "Live free or Die"? **A**: New Hampshire	**Article**: Live Free or Die **Paragraph**: "Live Free or Die" is the official motto of the U.S. state of New Hampshire, adopted by the state in 1945. It is possibly the best-known of all state mottos, partly because it conveys an assertive independence historically found in American political philosophy and partly because of its contrast to the milder sentiments found in other state mottos.
WebQuestions	**Q**: What part of the atom did Chadwick discover?† **A**: neutron	**Article**: Atom **Paragraph**: ... The atomic mass of these isotopes varied by integer amounts, called the whole number rule. The explanation for these different isotopes awaited the discovery of the neutron, an uncharged particle with a mass similar to the proton, by the physicist James Chadwick in 1932. ...
WikiMovies	**Q**: Who wrote the film Gigli? **A**: Martin Brest	**Article**: Gigli **Paragraph**: Gigli is a 2003 American romantic comedy film written and directed by Martin Brest and starring Ben Affleck, Jennifer Lopez, Justin Bartha, Al Pacino, Christopher Walken, and Lainie Kazan.

Table 1: Example training data from each QA dataset. In each case we show an associated paragraph where distant supervision (DS) correctly identified the answer within it, which is highlighted.

https://arxiv.org/pdf/1704.00051.pdf

SQuAD 1.0 → SQuAD 2.0

недостатки первой версии:
ответы на все вопросы есть в пределах параграфа
(во второй версии есть вариант «нет ответа»)

	SQuAD 1.1	SQuAD 2.0
Train		
Total examples	87,599	130,319
Negative examples	0	43,498
Total articles	442	442
Articles with negatives	0	285
Development		
Total examples	10,570	11,873
Negative examples	0	5,945
Total articles	48	35
Articles with negatives	0	35
Test		
Total examples	9,533	8,862
Negative examples	0	4,332
Total articles	46	28
Articles with negatives	0	28

Table 2: Dataset statistics of SQuAD 2.0, compared to the previous SQuAD 1.1.

https://arxiv.org/pdf/1806.03822.pdf

Данные: RACE http://www.cs.cmu.edu/~glai1/data/race/

5 типов вопросов: word matching, paraphrasing, single-sentence reasoning, multi-sentence reasoning, insucient or ambiguous questions

Passage:
In a small village in England about 150 years ago, a mail coach was standing on the street. It didn't come to that village often. People had to pay a lot to get a letter. The person who sent the letter didn't have to pay the postage, while the receiver had to.
"Here's a letter for Miss Alice Brown," said the mailman.
" I'm Alice Brown," a girl of about 18 said in a low voice.
Alice looked at the envelope for a minute, and then handed it back to the mailman.
"I'm sorry I can't take it, I don't have enough money to pay it", she said.
A gentleman standing around were very sorry for her. Then he came up and paid the postage for her.
When the gentleman gave the letter to her, she said with a smile, " Thank you very much, This letter is from Tom. I'm going to marry him. He went to London to look for work. I've waited a long time for this letter, but now I don't need it, there is nothing in it."
"Really? How do you know that?" the gentleman said in surprise.
"He told me that he would put some signs on the envelope. Look, sir, this cross in the corner means that he is well and this circle means he has found work. That's good news."
The gentleman was Sir Rowland Hill. He didn't forgot Alice and her letter.
"The postage to be paid by the receiver has to be changed," he said to himself and had a good plan.
"The postage has to be much lower, what about a penny? And the person who sends the letter pays the postage. He has to buy a stamp and put it on the envelope." he said . The government accepted his plan. Then the first stamp was put out in 1840. It was called the "Penny Black". It had a picture of the Queen on it.

Questions:

1): The first postage stamp was made _.
A. in England B. in America C. by Alice D. in 1910

2): The girl handed the letter back to the mailman because _ .
A. she didn't know whose letter it was
B. she had no money to pay the postage
C. she received the letter but she didn't want to open it
D. she had already known what was written in the letter

3): We can know from Alice's words that _ .
A. Tom had told her what the signs meant before leaving
B. Alice was clever and could guess the meaning of the signs
C. Alice had put the signs on the envelope herself
D. Tom had put the signs as Alice had told him to

4): The idea of using stamps was thought of by _ .
A. the government
B. Sir Rowland Hill
C. Alice Brown
D. Tom

5): From the passage we know the high postage made _ .
A. people never send each other letters
B. lovers almost lose every touch with each other
C. people try their best to avoid paying it
D. receivers refuse to pay the coming letters

Answer: ADABC

Table 1: Sample reading comprehension problems from our dataset.

Понимания языка (Language Understanding)

Что такое «понимание языка»?

Например, умение автоматически генерировать «желаемый ответ»

Когда ходят в школу?

Желаемые:
- **в детстве**
- **с сентября**

Не желаемые:
- **никогда**
- **вчера**

Что изображено на рисунке?

Желаемые:
- **бананы**
- **фрукты**

Не желаемые:
- **жёлтые объекты**

Свёрточные модели для текста

идея как в обработке n-грамм

$$\sigma\left(W\begin{bmatrix}x_1\\x_2\end{bmatrix}+b\right)$$

проблема – как работать с последовательностями произвольной длины

- RNN
- CNN + max-pooling (max over time pooling)

Свёрточные модели для текста

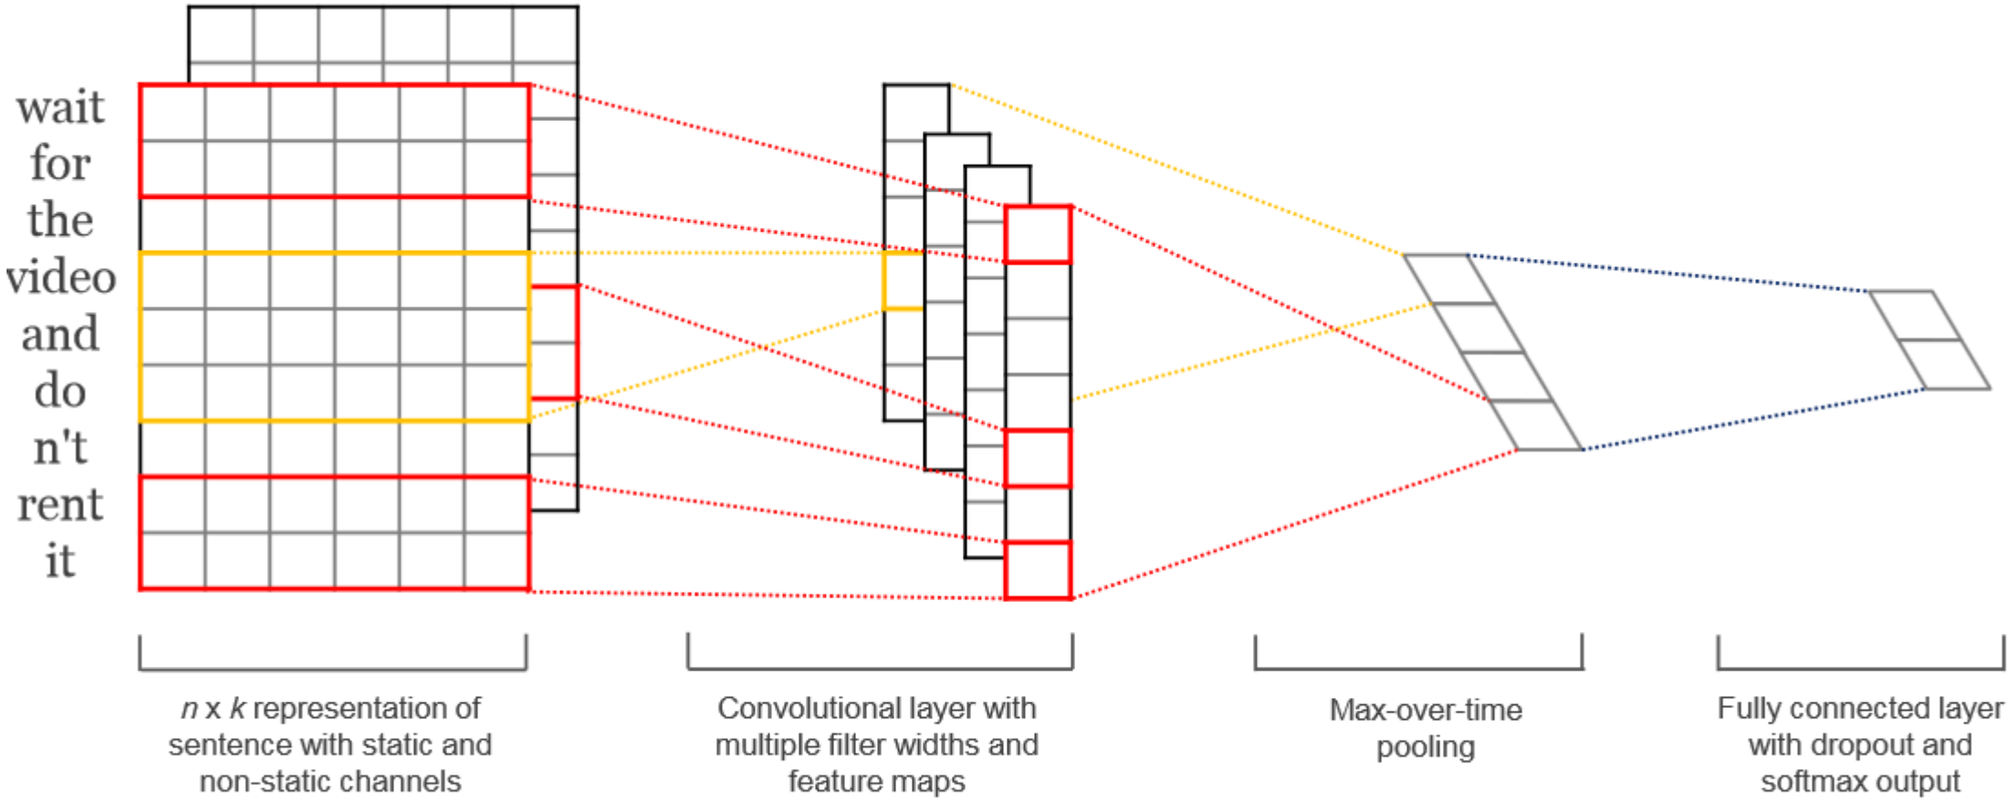

Figure 1: Model architecture with two channels for an example sentence.

два входных канала, т.к. были и эксперименты, когда один канал обучался…

Yoon Kim «Convolutional Neural Networks for Sentence Classification» // https://arxiv.org/abs/1408.5882

Свёрточные модели для текста

k – длина представления слова

n – фиксированная длина предложения

(если меньше – фиктивно набавляем)

Теперь уже наше предложение – матрица (как изображение)

подматрица векторизуется

$$c_i = \sigma\left(W_{1\times hk} \begin{bmatrix} x_i \\ \cdots \\ x_{i+h-1} \end{bmatrix}_{hk\times 1} + b \right) \in \mathbb{R}$$

на втором слое (если один фильтр):

$$c = [c_1, \ldots, c_{n-h+1}] \in \mathbb{R}^{n-h+1}$$

max-pooling

$$\max(c) \in \mathbb{R}$$

для нескольких слоёв аналогично → полносвязную сеть

Свёрточные модели для текста: улучшения

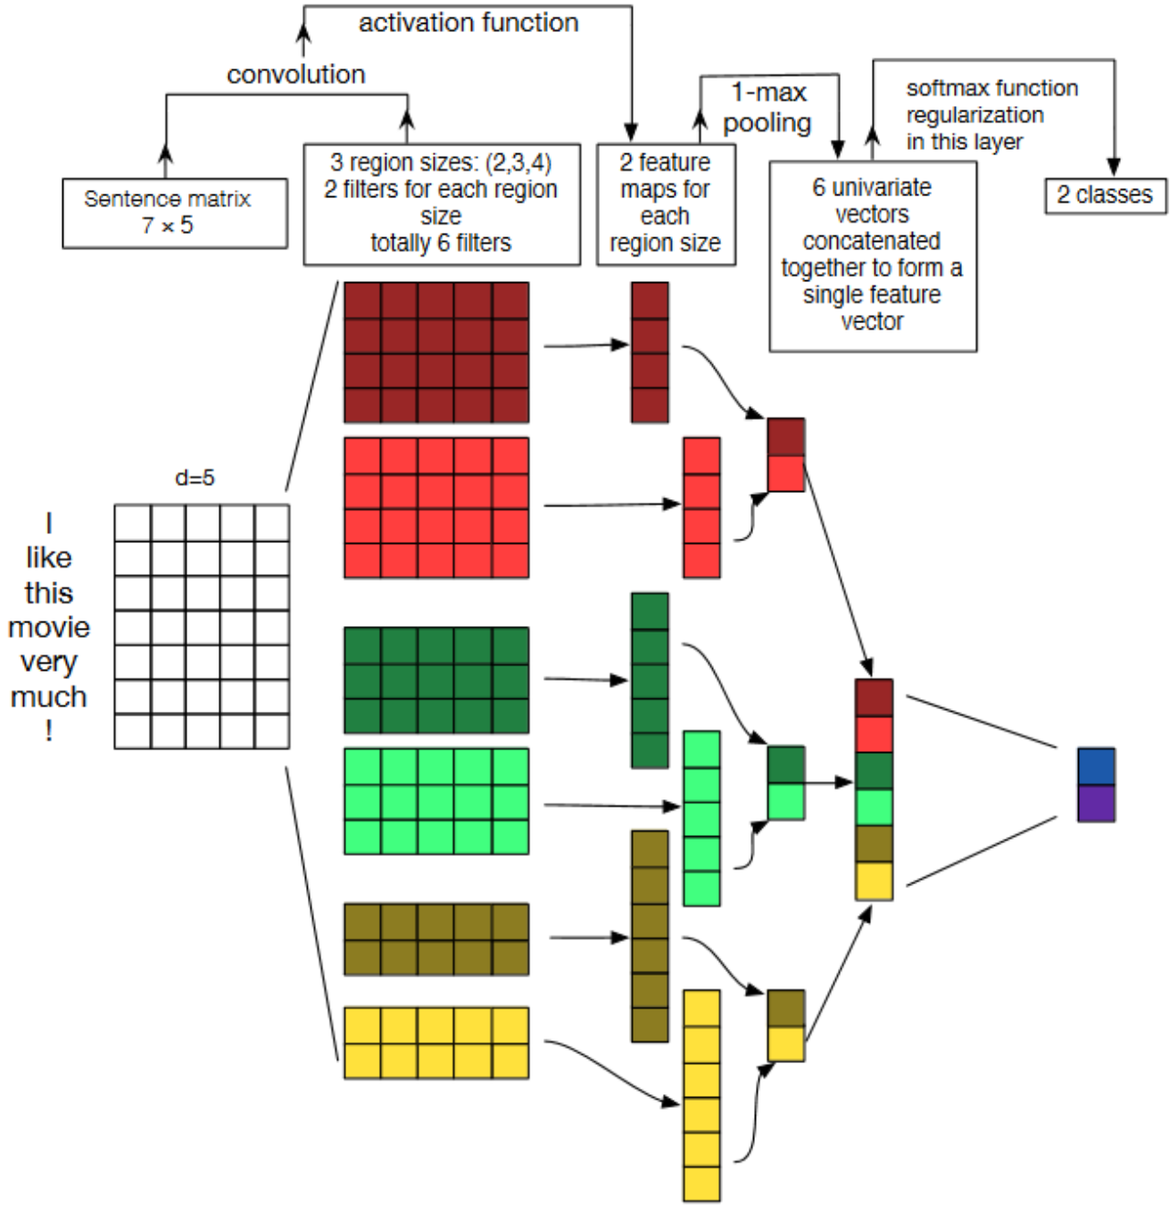

Свёртки с разной шириной

Разделить пулинг и конкатенацию

Ye Zhang, Byron Wallace A Sensitivity Analysis of (and Practitioners' Guide to) Convolutional Neural Networks for Sentence Classification https://arxiv.org/abs/1510.03820

Dynamic Convolutional Neural Network

есть возможность получения такого графа:

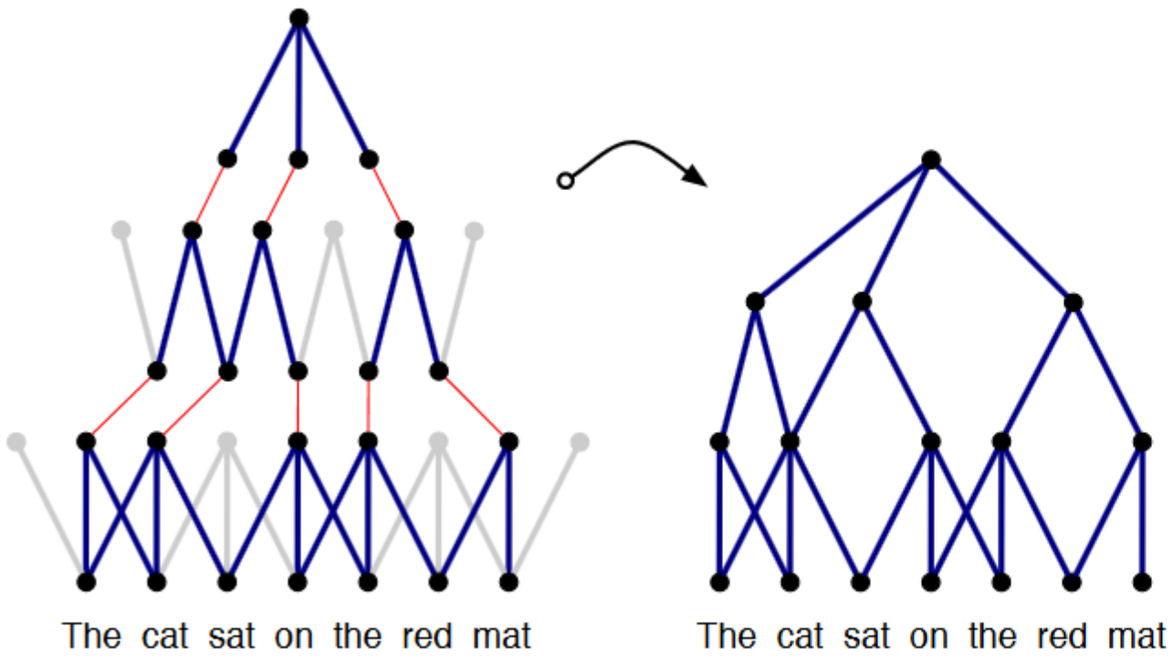

Figure 1: Subgraph of a feature graph induced over an input sentence in a Dynamic Convolutional Neural Network. The full induced graph has multiple subgraphs of this kind with a distinct set of edges; subgraphs may merge at different layers. The left diagram emphasises the pooled nodes. The width of the convolutional filters is 3 and 2 respectively. With dynamic pooling, a filter with small width at the higher layers can relate phrases far apart in the input sentence.

Nal Kalchbrenner, Edward Grefenstette, Phil Blunsom «A Convolutional Neural Network for Modelling Sentences» https://arxiv.org/abs/1404.2188

Dynamic Convolutional Neural Network: центральные понятия

Узкие и широкие свёртки

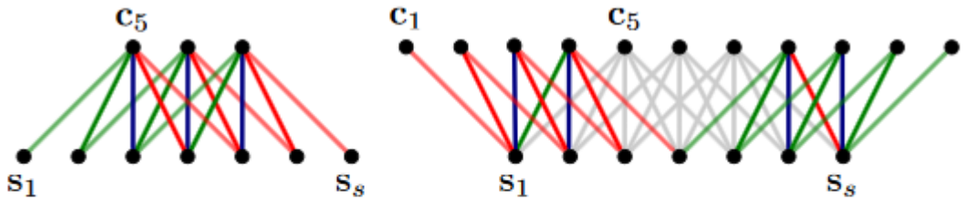

Figure 2: Narrow and wide types of convolution. The filter $\mathbf{m}$ has size $m = 5$.

Узкая одномерная свёртка $R^s * R^m \to R^{s-m+1}$

Широкая одномерная свёртка $R^s * R^m \to R^{s+m+1}$

идёт дополнение нулями и все веса ядра «касаются» всех элементов

k-пулинг – k наибольших элементов

[1, 2, 5, 3, 4] → [5, 4, 3]

динамический k-пулинг – k – функция от входов и параметров сети

(например от длины входа и глубины сети)

чтобы в конце – фиксированная длина

сначала широкая свёртка

(dynamic) k-max pooling

нелинейность

получаем несколько карт признаков

свёртка по всем картам

т.е. сумма свёрток со своими весами

Folding – сумма по 2 строчки

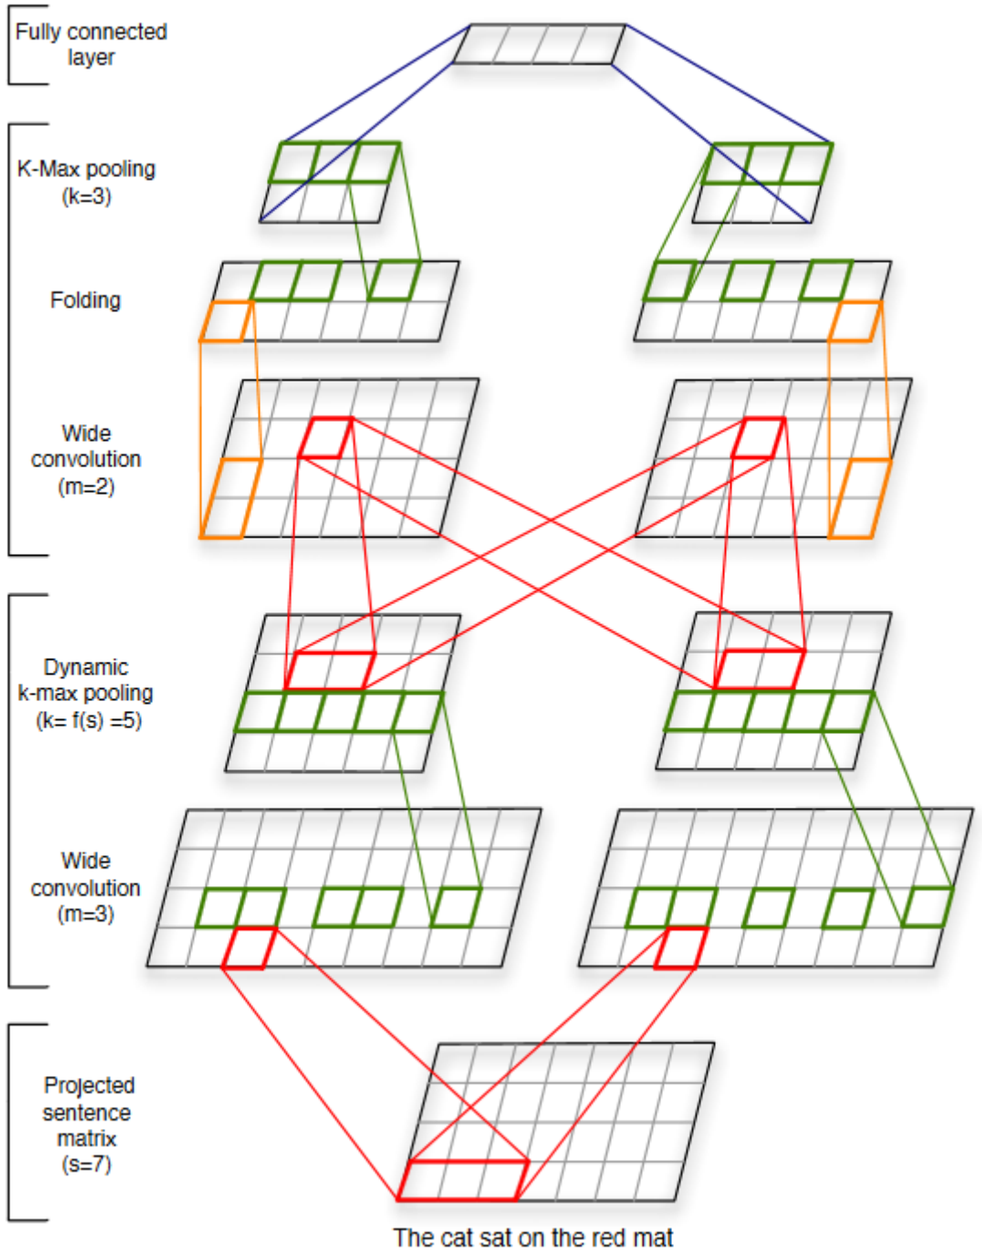

Figure 3: A DCNN for the seven word input sentence. Word embeddings have size $d = 4$. The network has two convolutional layers with two feature maps each. The widths of the filters at the two layers are respectively 3 and 2. The (dynamic) k-max pooling layers have values k of 5 and 3.

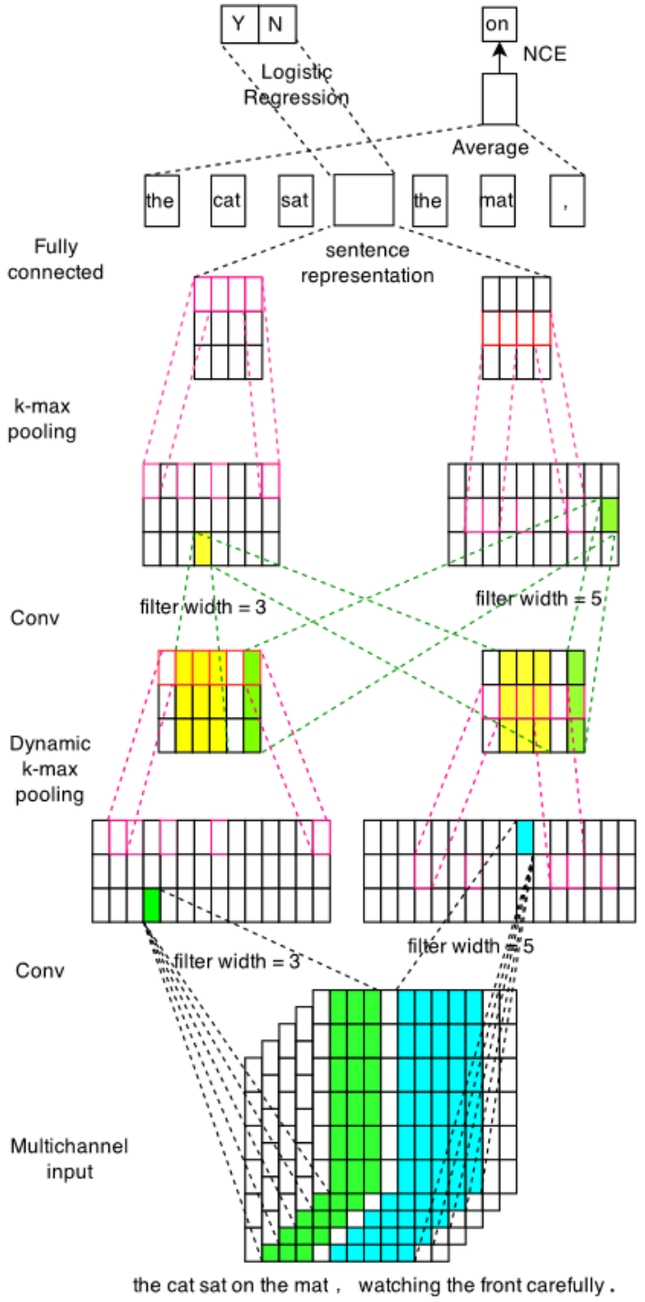

Multi Channel Variable size CNN: MV-CNN

Продолжение идеи…

Сразу использовать несколько представлений:

- glove
- word2vec
- custom trained vectors

поэтому многоканальный вход

Wenpeng Yin, Hinrich Schütze «Multichannel Variable-Size Convolution for Sentence Classification» // https://arxiv.org/abs/1603.04513

Very Deep Convolutional Networks for Text Classification: VD-CNN

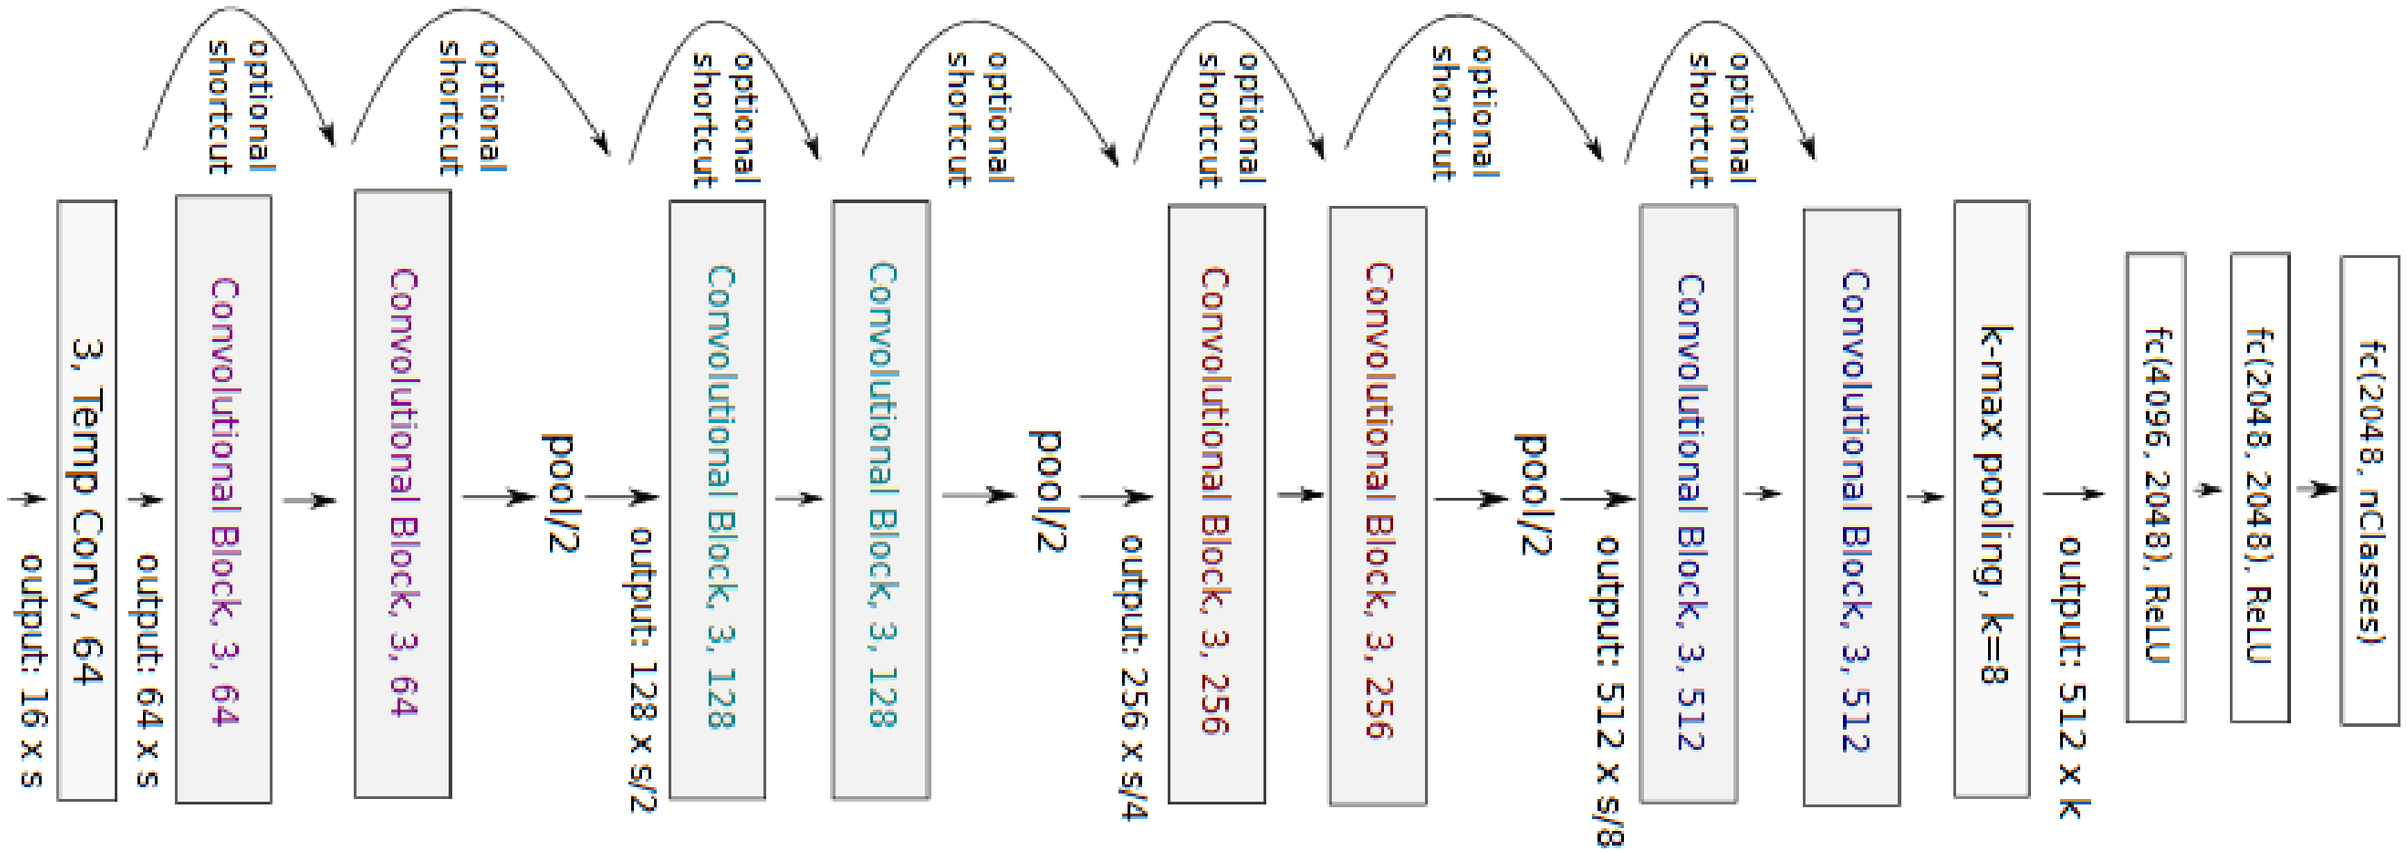

хороши в посимвольном случае (character-level)

маленькие свёртки и маленькие пулинги (окно=3)

до 29 свёрточных слоёв

Very Deep Convolutional Networks for Text Classification: VD-CNN

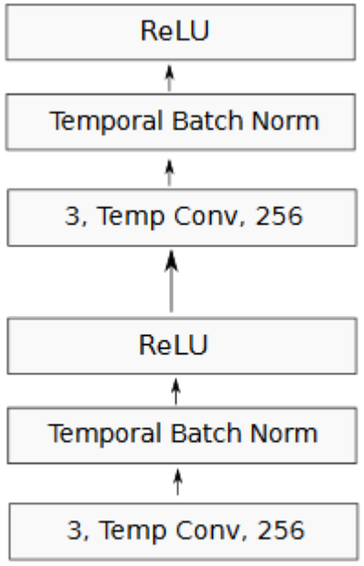

Figure 2: Convolutional block.

сделана по аналогии с VGG:

когда пространственный размер уменьшается в 2 раза

– число каналов×2

Temporal BN – для минибатча из m объектов на посл-ти длины s

статистики считаются по m·s слагаемым

Alexis Conneau, Holger Schwenk, Loïc Barrault, Yann Lecun «Very Deep Convolutional Networks for Text Classification» // https://arxiv.org/abs/1606.01781

Very Deep Convolutional Networks for Text Classification: VD-CNN

Depth	Pooling	AG	Sogou	DBP.	Yelp P.	Yelp F.	Yah. A.	Amz. F.	Amz. P.
9	Convolution	10.17	4.22	1.64	5.01	37.63	28.10	38.52	4.94
9	KMaxPooling	9.83	3.58	1.56	5.27	38.04	28.24	39.19	5.69
9	MaxPooling	9.17	3.70	1.35	4.88	36.73	27.60	37.95	4.70
17	Convolution	9.29	3.94	1.42	4.96	36.10	27.35	37.50	4.53
17	KMaxPooling	9.39	3.51	1.61	5.05	37.41	28.25	38.81	5.43
17	MaxPooling	8.88	3.54	1.40	4.50	36.07	27.51	37.39	4.41
29	Convolution	9.36	3.61	1.36	4.35	**35.28**	27.17	37.58	**4.28**
29	KMaxPooling	**8.67**	**3.18**	1.41	4.63	37.00	27.16	38.39	4.94
29	MaxPooling	8.73	3.36	**1.29**	**4.28**	35.74	**26.57**	**37.00**	4.31

Table 5: Testing error of our models on the 8 data sets. No data preprocessing or augmentation is used.

depth	without shortcut	with shortcut
9	37.63	40.27
17	36.10	39.18
29	35.28	36.01
49	37.41	36.15

Table 6: Test error on the Yelp Full data set for all depths, with or without residual connections.

- **глубина важна**
- **max-pool лучше всего**
- **эта модель лучше предыдущих**
- **прокидывание связей помогает на глубине**

Сравнение CNN vs RNN

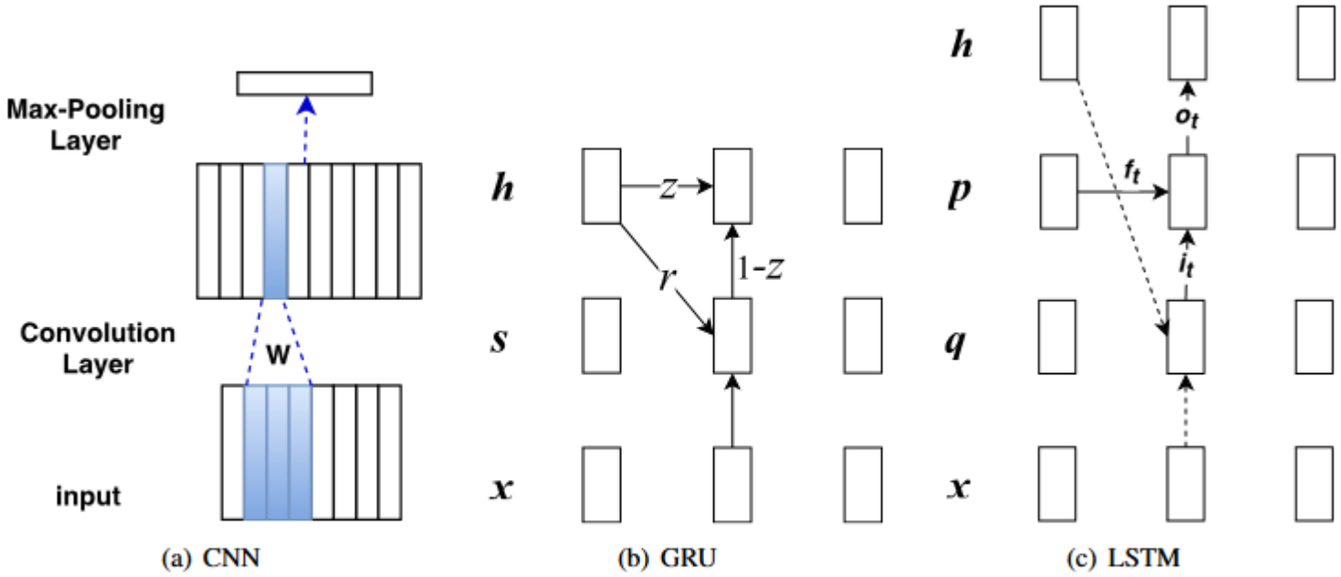

Figure 1: Three typical DNN architectures

задачи

- Sentiment Classification (SentiC)
- Relation Classification (RC)
- Textual Entailment (TE)
- Answer Selection (AS)
- Question Relation Match (QRM)
- Path Query Answering (PQA)
- Part-of-Speech Tagging

Wenpeng Yin et al.«Comparative Study of CNN and RNN for Natural Language Processing»
https://arxiv.org/pdf/1702.01923.pdf

Сравнение CNN vs RNN: нет явного победителя!

			performance	lr	hidden	batch	sentLen	filter_size	margin
TextC	SentiC (acc)	CNN	82.38	0.2	20	5	60	3	–
		GRU	**86.32**	0.1	30	50	60	–	–
		LSTM	84.51	0.2	20	40	60	–	–
	RC (F1)	CNN	68.02	0.12	70	10	20	3	–
		GRU	**68.56**	0.12	80	100	20	–	–
		LSTM	66.45	0.1	80	20	20	–	–
SemMatch	TE (acc)	CNN	77.13	0.1	70	50	50	3	–
		GRU	**78.78**	0.1	50	80	65	–	–
		LSTM	77.85	0.1	80	50	50	–	–
	AS (MAP & MRR)	CNN	**(63.69,65.01)**	0.01	30	60	40	3	0.3
		GRU	(62.58,63.59)	0.1	80	150	40	–	0.3
		LSTM	(62.00,63.26)	0.1	60	150	45	–	0.1
	QRM (acc)	CNN	**71.50**	0.125	400	50	17	5	0.01
		GRU	69.80	1.0	400	50	17	-	0.01
		LSTM	71.44	1.0	200	50	17	-	0.01
SeqOrder	PQA (hit@10)	CNN	54.42	0.01	250	50	5	3	0.4
		GRU	**55.67**	0.1	250	50	5	–	0.3
		LSTM	55.39	0.1	300	50	5	–	0.3
ContextDep	POS tagging (acc)	CNN	94.18	0.1	100	10	60	5	–
		GRU	93.15	0.1	50	50	60	–	–
		LSTM	93.18	0.1	200	70	60	–	–
		Bi-GRU	94.26	0.1	50	50	60	–	–
		Bi-LSTM	**94.35**	0.1	150	5	60	–	–

Table 1: Best results or CNN, GRU and LSTM in NLP tasks

Сравнение CNN vs RNN vs HAN

HAN – Hierarchical Attention Network

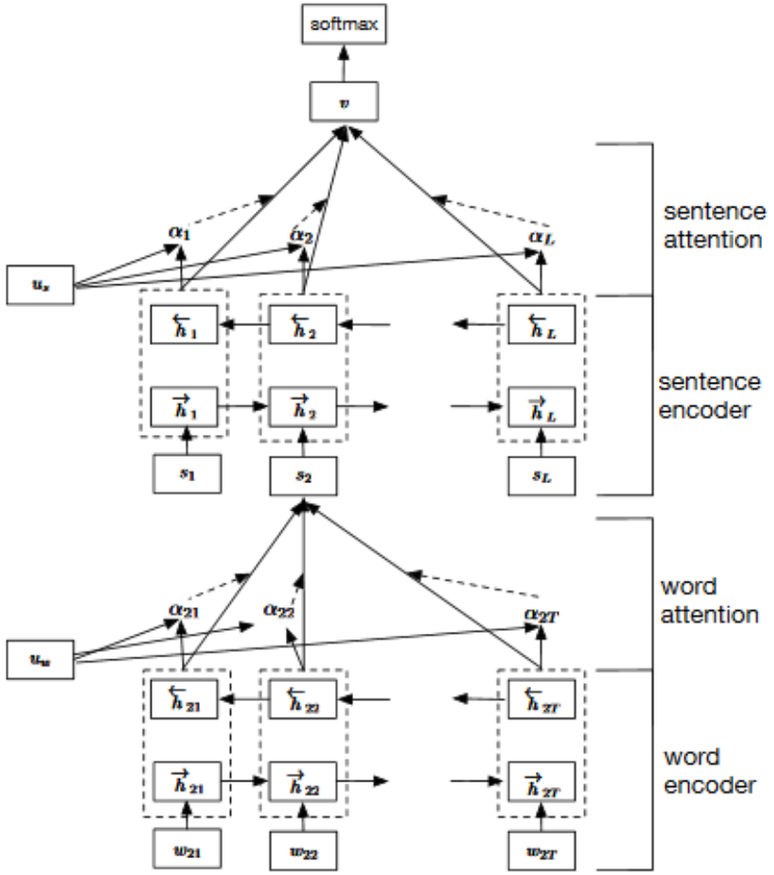

Figure 2: Hierarchical Attention Network.

детали этой сети пока опустим

https://medium.com/jatana/report-on-text-classification-using-cnn-rnn-han-f0e887214d5f

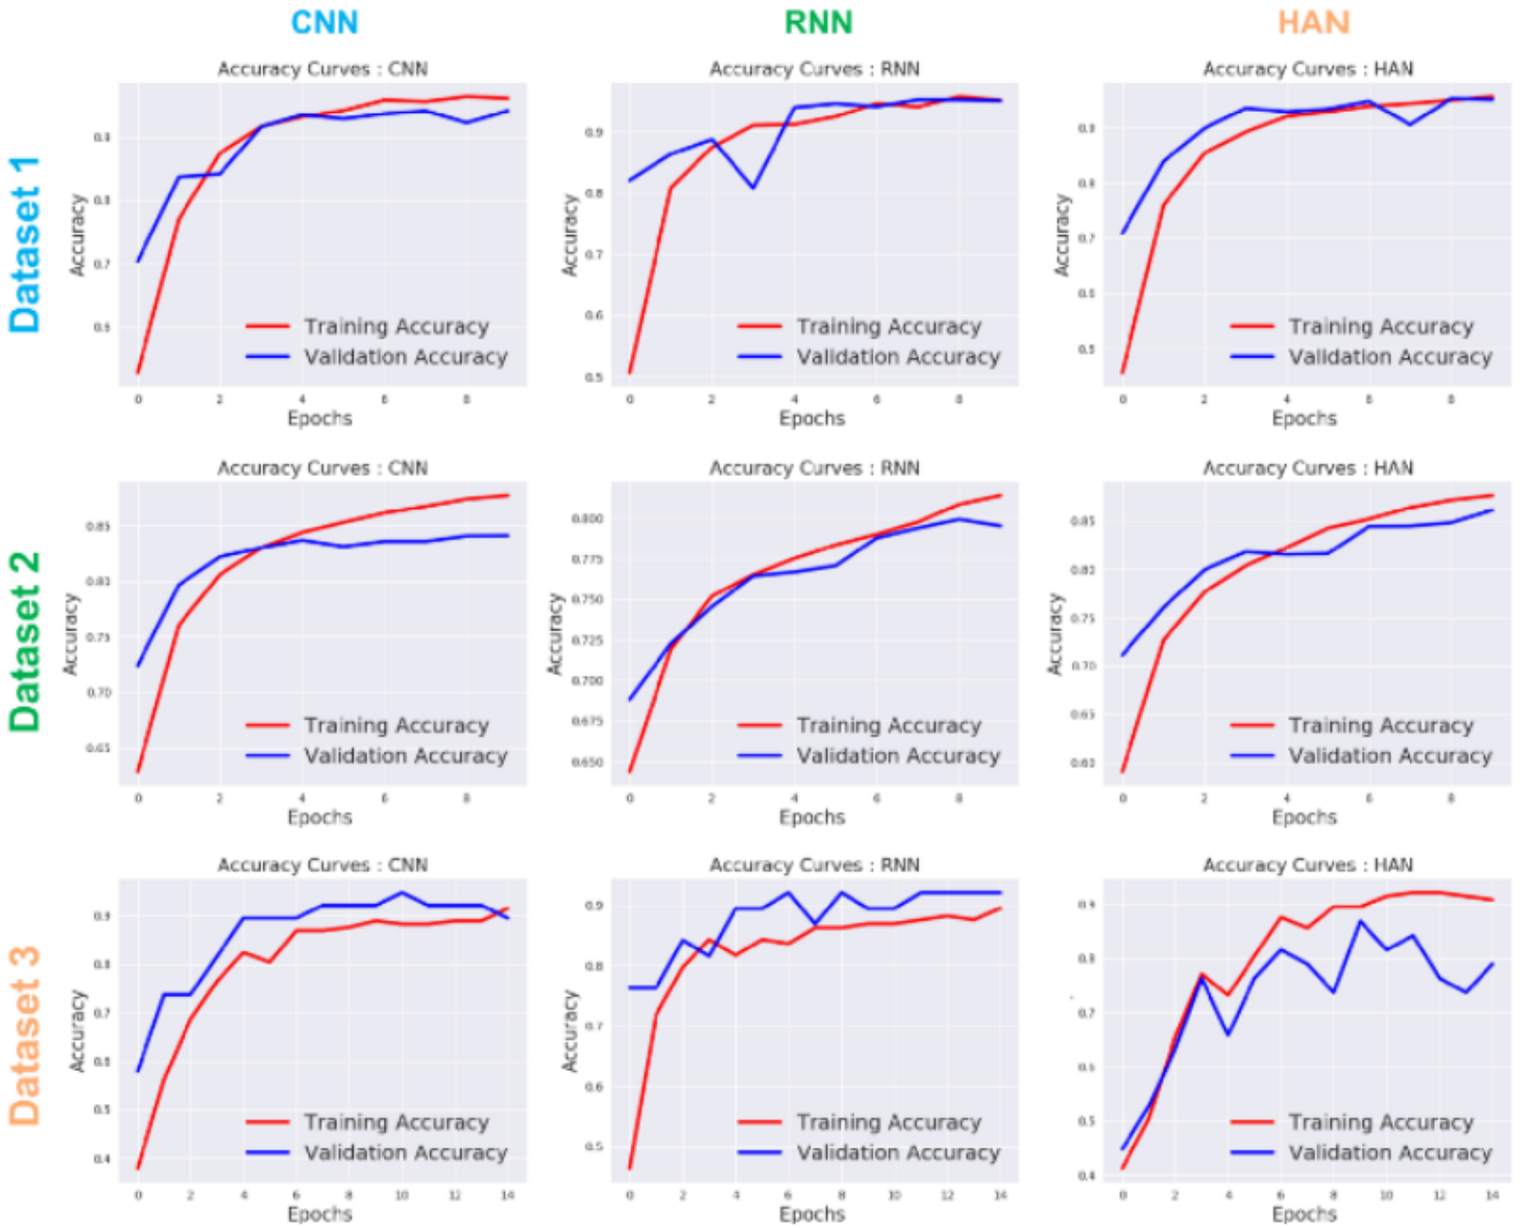

здесь CNN чуть получше

CNN + LSTM = C-LSTM

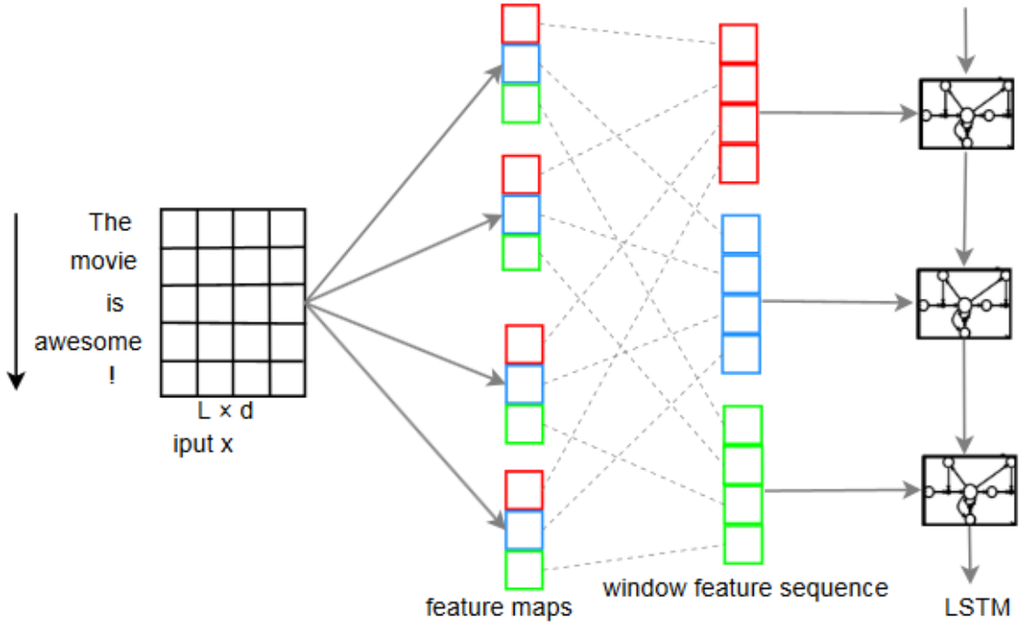

Figure 1: The architecture of C-LSTM for sentence modeling. Blocks of the same color in the feature map layer and window feature sequence layer corresponds to features for the same window. The dashed lines connect the feature of a window with the source feature map. The final output of the entire model is the last hidden unit of LSTM.

CNN – получение высокоуровневых признаков из представлений слов

LSTM – для анализа зависимостей

Chunting Zhou, Chonglin Sun, Zhiyuan Liu, Francis C.M. Lau «A C-LSTM Neural Network for Text Classification»
https://arxiv.org/abs/1511.08630

CNN + LSTM + CRF = LSTM-CNNs-CRF

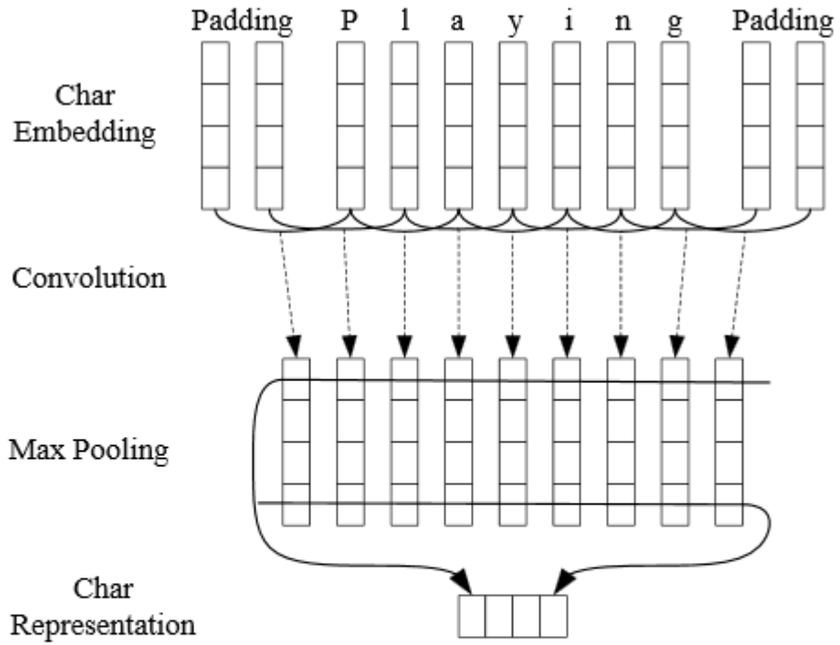

Figure 1: The convolution neural network for extracting character-level representations of words. Dashed arrows indicate a dropout layer applied before character embeddings are input to CNN.

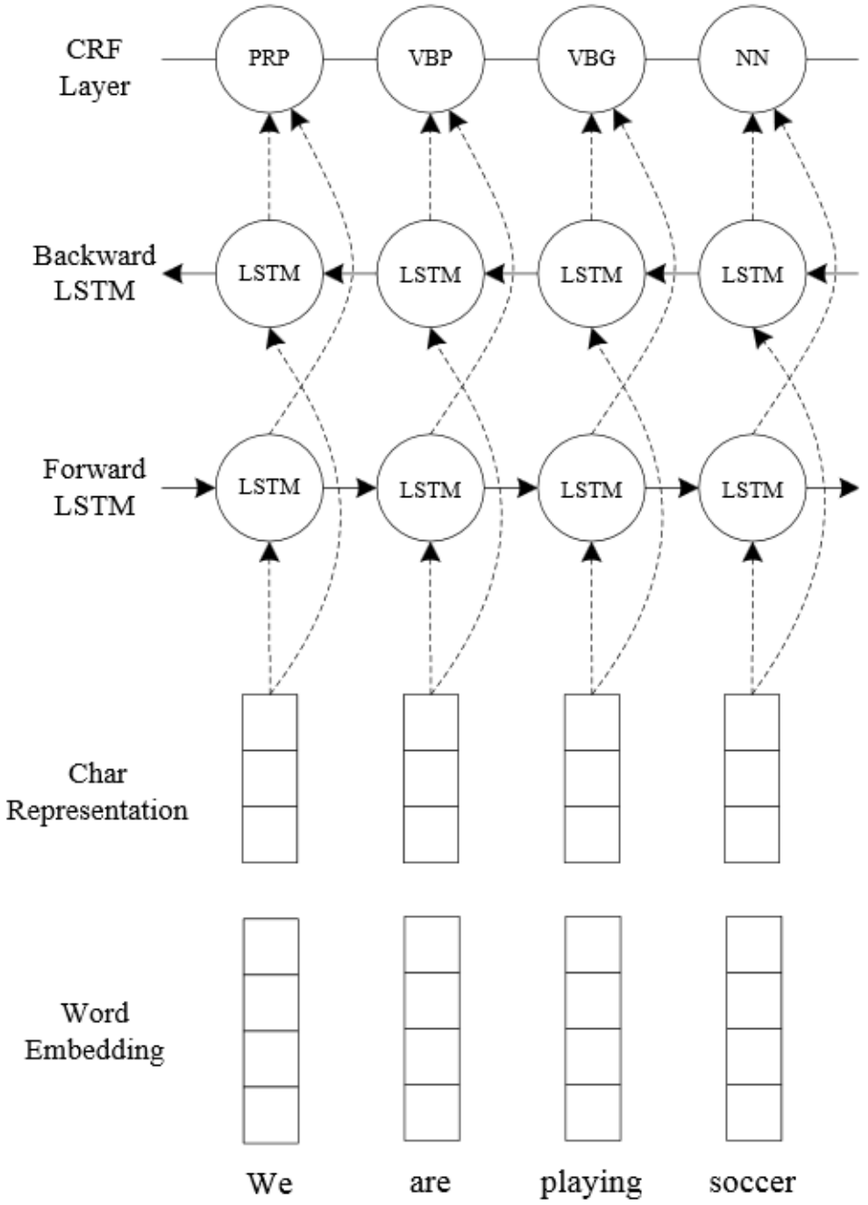

Dashed arrows indicate dropout layers applied on both the input and output vectors of BLSTM.

CNN + LSTM + CRF = LSTM-CNNs-CRF

	POS		NER					
	Dev	Test	Dev			Test		
Model	Acc.	Acc.	Prec.	Recall	F1	Prec.	Recall	F1
BRNN	96.56	96.76	92.04	89.13	90.56	87.05	83.88	85.44
BLSTM	96.88	96.93	92.31	90.85	91.57	87.77	86.23	87.00
BLSTM-CNN	97.34	97.33	92.52	93.64	93.07	88.53	90.21	89.36
BRNN-CNN-CRF	97.46	97.55	94.85	94.63	94.74	91.35	91.06	91.21

Table 3: Performance of our model on both the development and test sets of the two tasks, together with three baseline systems.

Xuezhe Maand, Eduard Hovy «End-to-end Sequence Labeling via Bi-directional LSTM-CNNs-CRF» // https://arxiv.org/pdf/1603.01354.pdf

Модель seq2seq

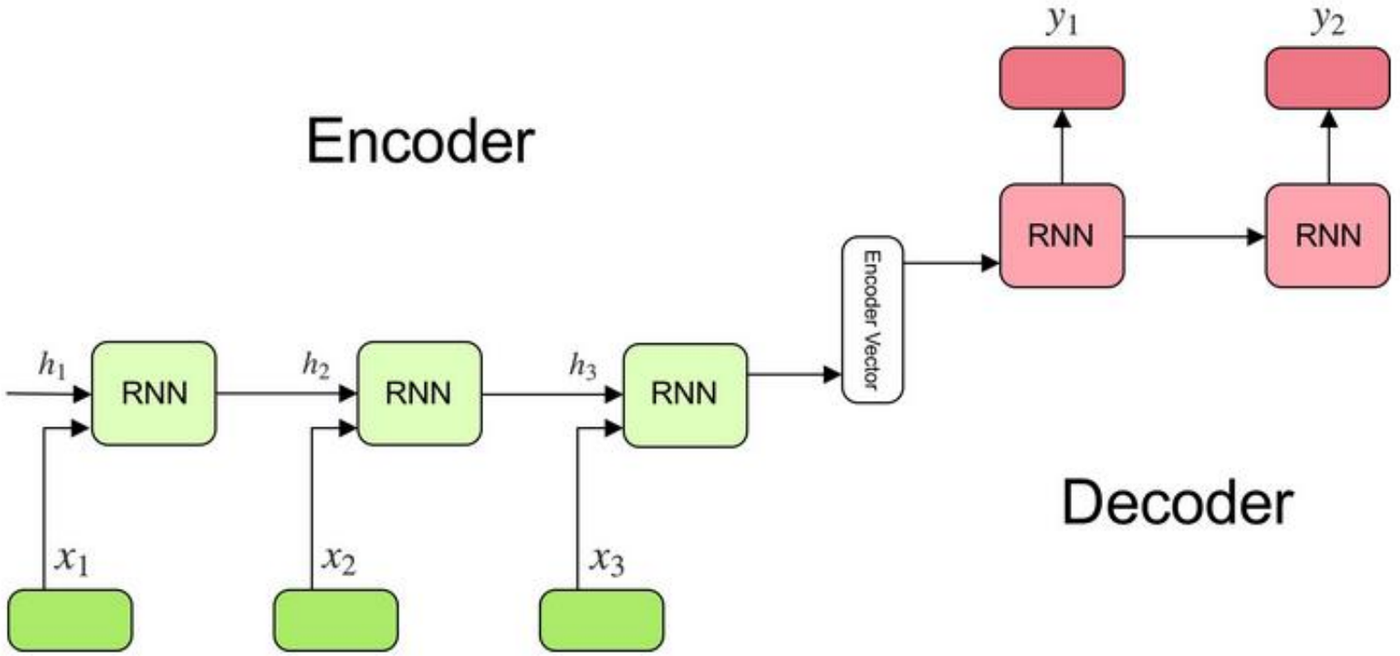

http://www.davidsbatista.net/blog/2020/01/25/Attention-seq2seq/

Sutskever I. «Sequence to Sequence Learning with Neural Networks», 2014 // https://arxiv.org/abs/1409.3215

Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation

Kyunghyun Cho et. al. «Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation» https://www.aclweb.org/anthology/D14-1179/

Модель seq2seq: как переводить последовательность → последовательность

Многослойная (4 слоя) LSTM

размерность представления = 1000

входной словарь = 160,000

выходной словарь = 80,000

кодировщик (encoder) – декодировщик (decoder)

кодировщик: входная последовательность → вектор

декодировщик: вектор → таргетная последовательность

Это разные LSTM, у них разные параметры!

Интересно: в задаче перевода качество повышало инвертирование порядка входа!

Обучение 10 дней

Тоже хороши ансамбли

Модель seq2seq

здесь декодировщик называют также **языковой моделью**

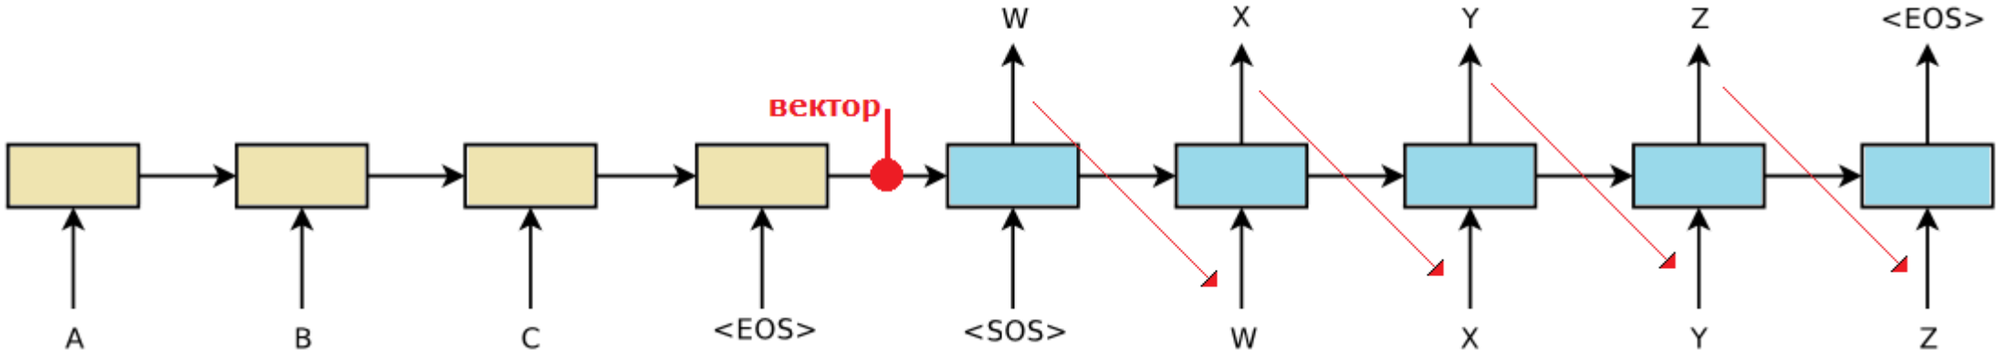

при работе (inference) – подаём на вход сгенерированное

при обучении – среднее ошибок на всех выходах (ex negative log prob)

тонкости:

на рисунке в декодировщике передаётся только его внутреннее состояние

выход кодировщика передаётся лишь первому элементу

можно его передавать всем – чтобы информация о входе была у всех

Модель seq2seq: внутреннее представление предложений

Figure 2: The figure shows a 2-dimensional PCA projection of the LSTM hidden states that are obtained after processing the phrases in the figures. The phrases are clustered by meaning, which in these examples is primarily a function of word order, which would be difficult to capture with a bag-of-words model. Notice that both clusters have similar internal structure.

left-to-right beam-search decode потом будет

если выбираем лучшего следующего, не обязательно максимизируем качество

Обобщения seq2seq

На одном нейроне вся информация о тексте… плохо

(особенно для длинных последовательностей)

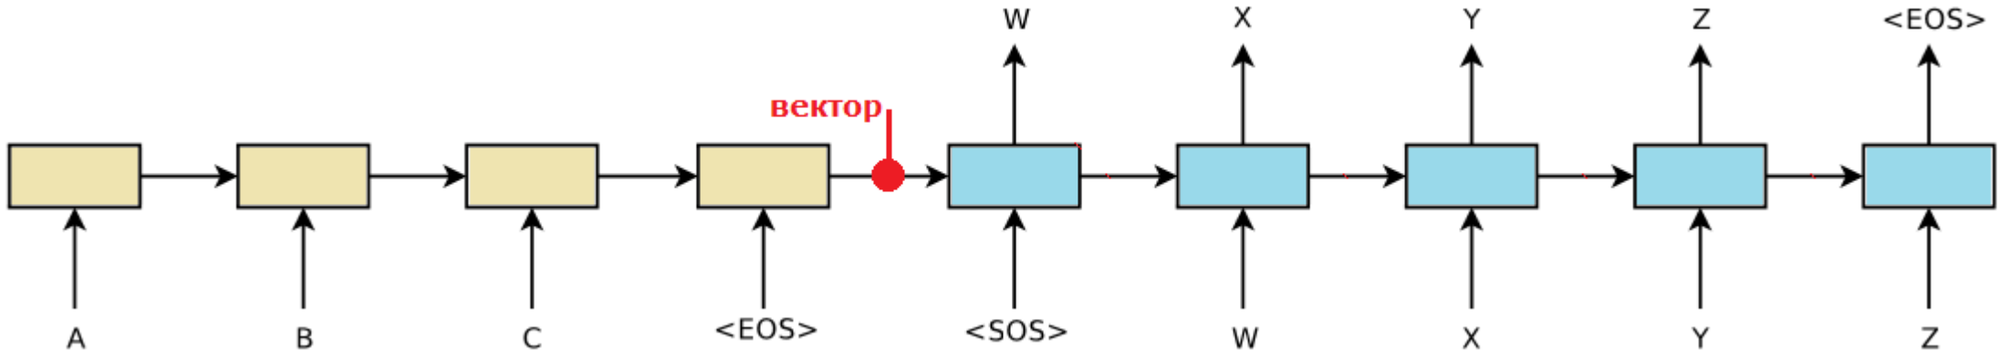

Решение – механизм внимания

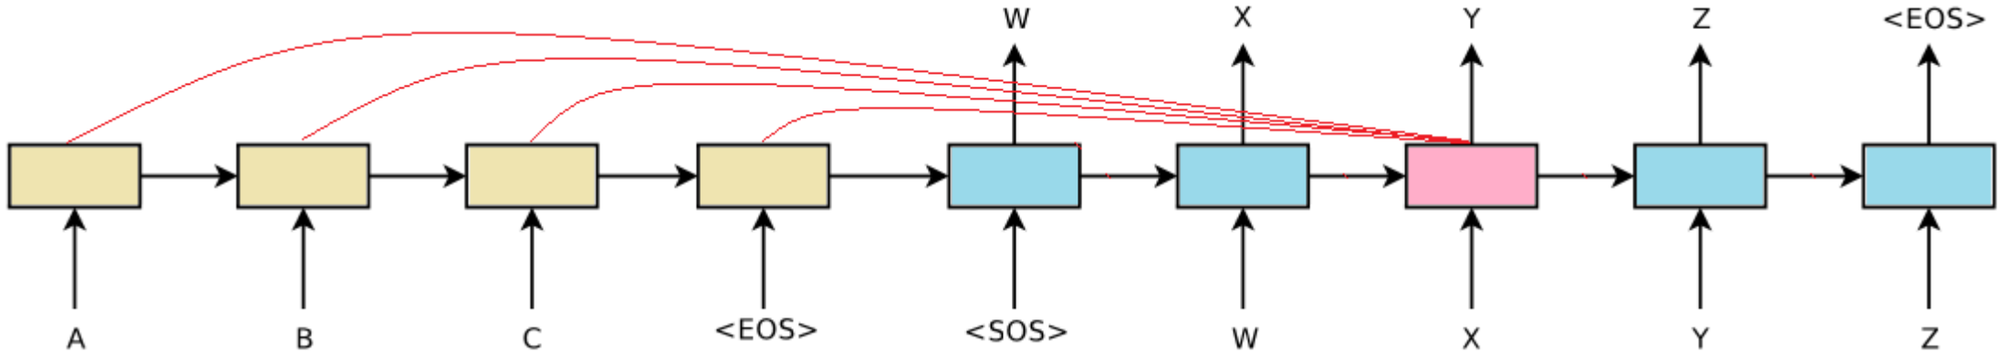

Bahdanau et al. 2015 «Neural Machine Translation by Jointly Learning to Align and Translate» // ICLR 2015 https://arxiv.org/pdf/1409.0473.pdf

Механизм внимания

Концепция: есть взаимосвязи между словами

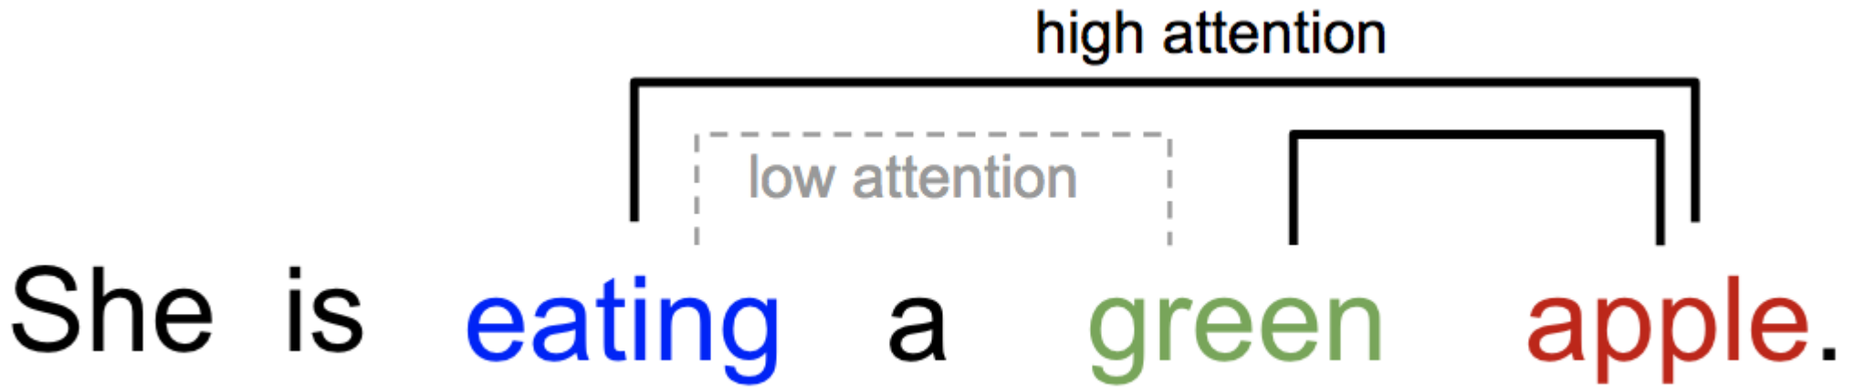

кодировщик передаёт в декодировщик не только одно состояние,
а состояния всех токенов!

– но для этого нужен механизм пулинга посл-ти состояний любой длины

выход – пулинг по схожести

https://lilianweng.github.io/lil-log/2018/06/24/attention-attention.html#born-for-translation

Механизм внимания

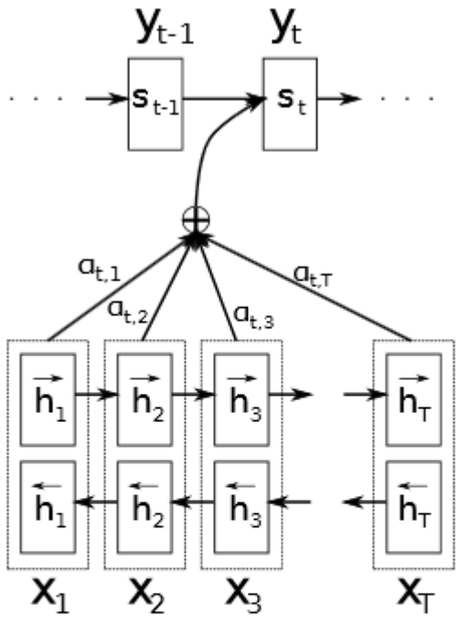

Figure 1: The graphical illustration of the proposed model trying to generate the t-th target word y_t given a source sentence $(x_1, x_2, \ldots, x_T)$.

Не будем пытаться закодировать всё предложение одним вектором!

Добавляется контекстный вектор (конкатенируется)

$$c_i = \sum_j \alpha_{ij} h_j$$

веса (softmax)

$$\alpha_{ij} = \exp(e_{ij}) / \sum_k \exp(e_{ik})$$

Насколько соответствуют состояния

$$e_{ij} = a(s_{i-1}, h_j)$$

Bidirectional RNN (BiRNN) $\Rightarrow$

учитываются не только слова ДО, но и ПОСЛЕ

Конкатенация состояния ДО и состояния ПОСЛЕ

Механизм внимания

соответствие $e_{ij} = a(s_{i-1}, h_j)$ **может быть:**

Basic dot-product https://arxiv.org/pdf/1508.04025.pdf	$a(s,h) = s^{\mathrm{T}} h$
Multiplicative attention https://arxiv.org/pdf/1508.04025.pdf	$a(s,h) = s^{\mathrm{T}} W h$
Additive attention https://arxiv.org/pdf/1409.0473.pdf	$a(s,h) = w^{\mathrm{T}} \tanh(W_1 s - W_2 h) = w^{\mathrm{T}} \tanh(W[s;h])$
Scaled dot-product http://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf	$a(s,h) = s^{\mathrm{T}} h / \sqrt{d}$
Content-base attention https://arxiv.org/abs/1410.5401	$a(s,h) = \cos(s,h)$

+ разные нормировки по размерности

Thang Luong, Hieu Pham, Christopher D. Manning «Effective Approaches to Attention-based Neural Machine Translation» https://www.aclweb.org/anthology/D15-1166.pdf

Механизм внимания

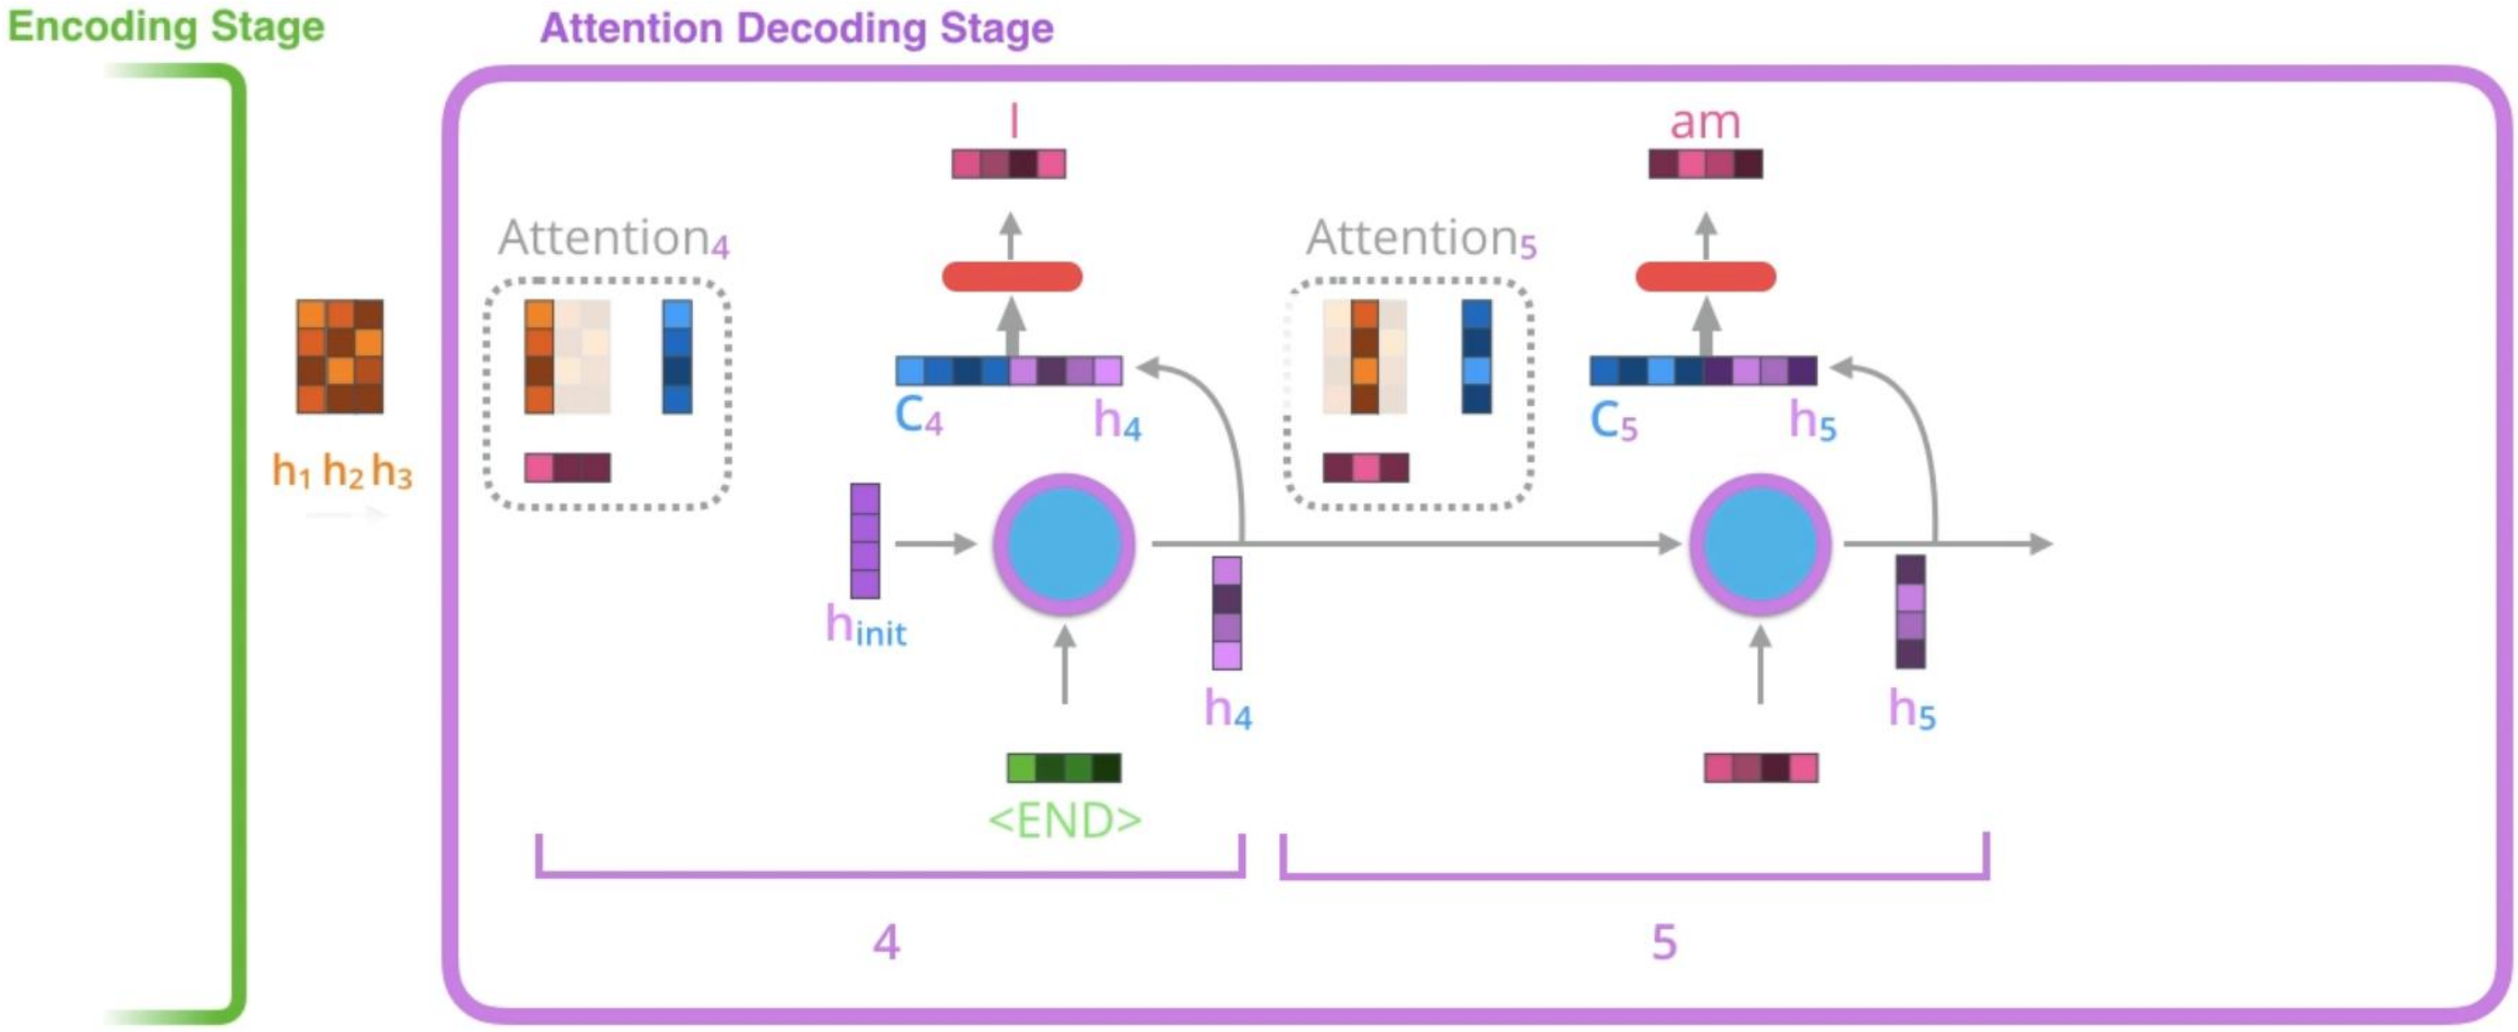

полученный в л/к состояний кодировщика вектор конкатенируем с текущим состоянием

Механизм внимания: получаем интерпретацию и выравнивание (alignment)

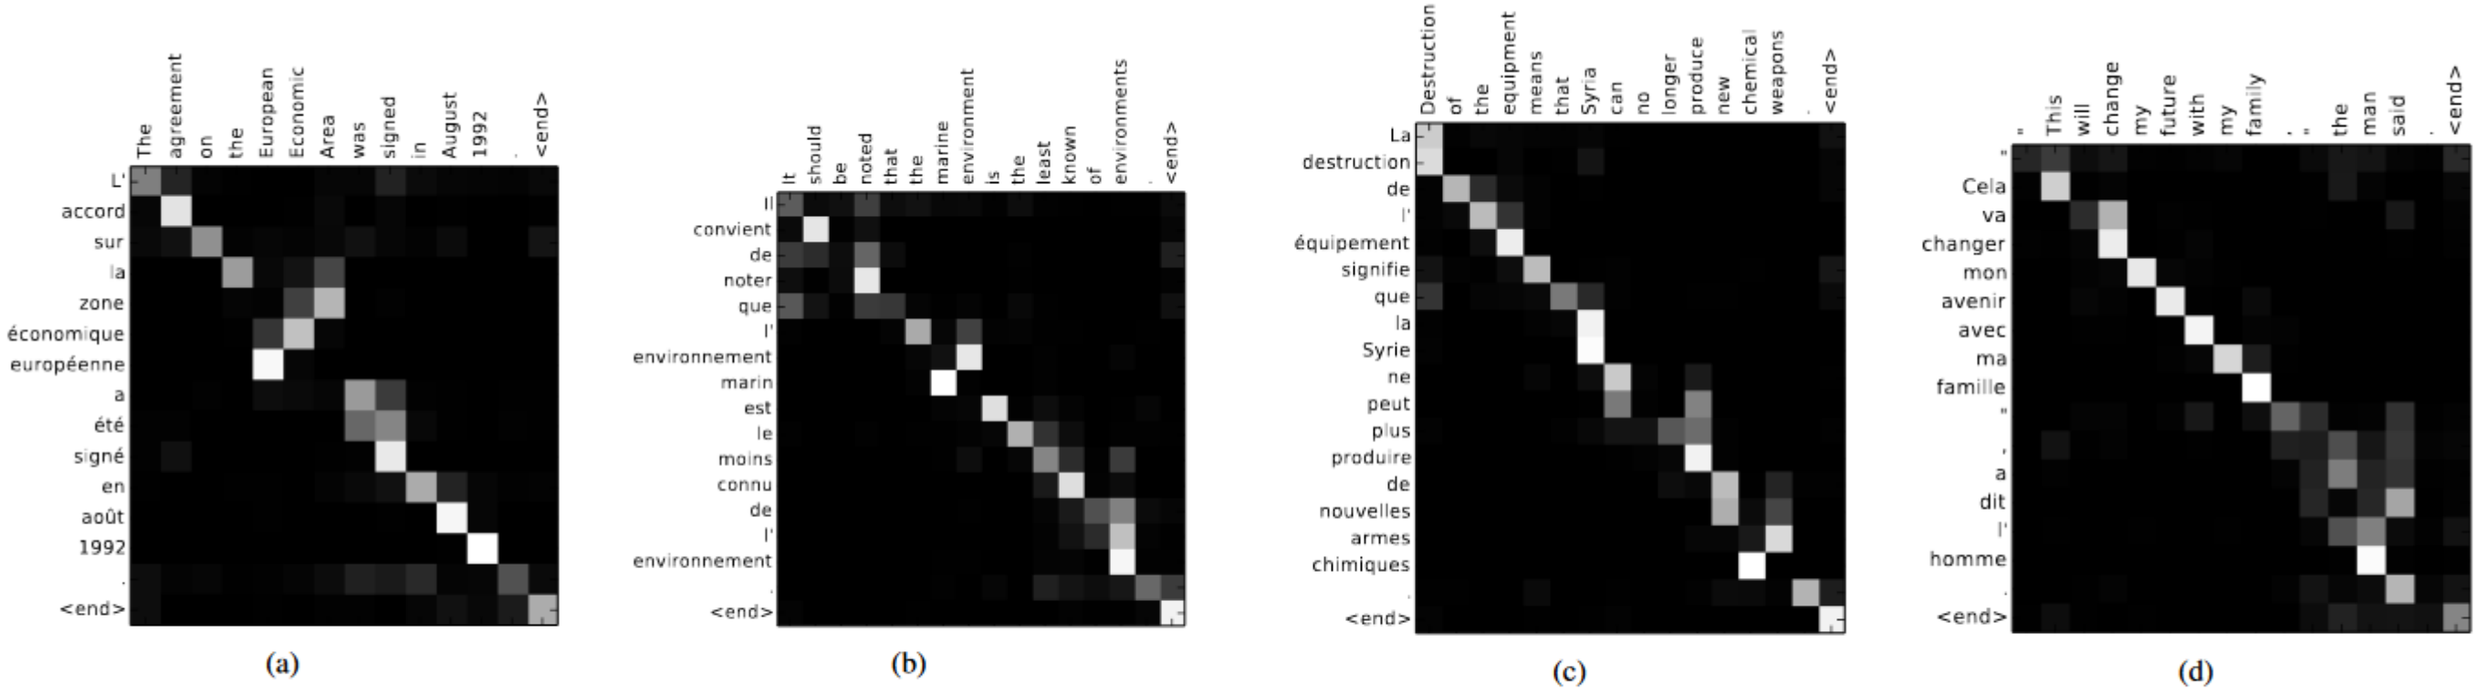

Figure 3: Four sample alignments found by RNNsearch-50. The x-axis and y-axis of each plot correspond to the words in the source sentence (English) and the generated translation (French), respectively. Each pixel shows the weight α_{ij} of the annotation of the j-th source word for the i-th target word (see Eq. (6)), in grayscale (0: black, 1: white). (a) an arbitrary sentence. (b–d) three randomly selected samples among the sentences without any unknown words and of length between 10 and 20 words from the test set.

Bahdanau D. и др. «Neural Machine Translation by Jointly Learning to Align and Translate» // https://arxiv.org/abs/1409.0473

Механизм внимания: решение проблемы «узкого горла»

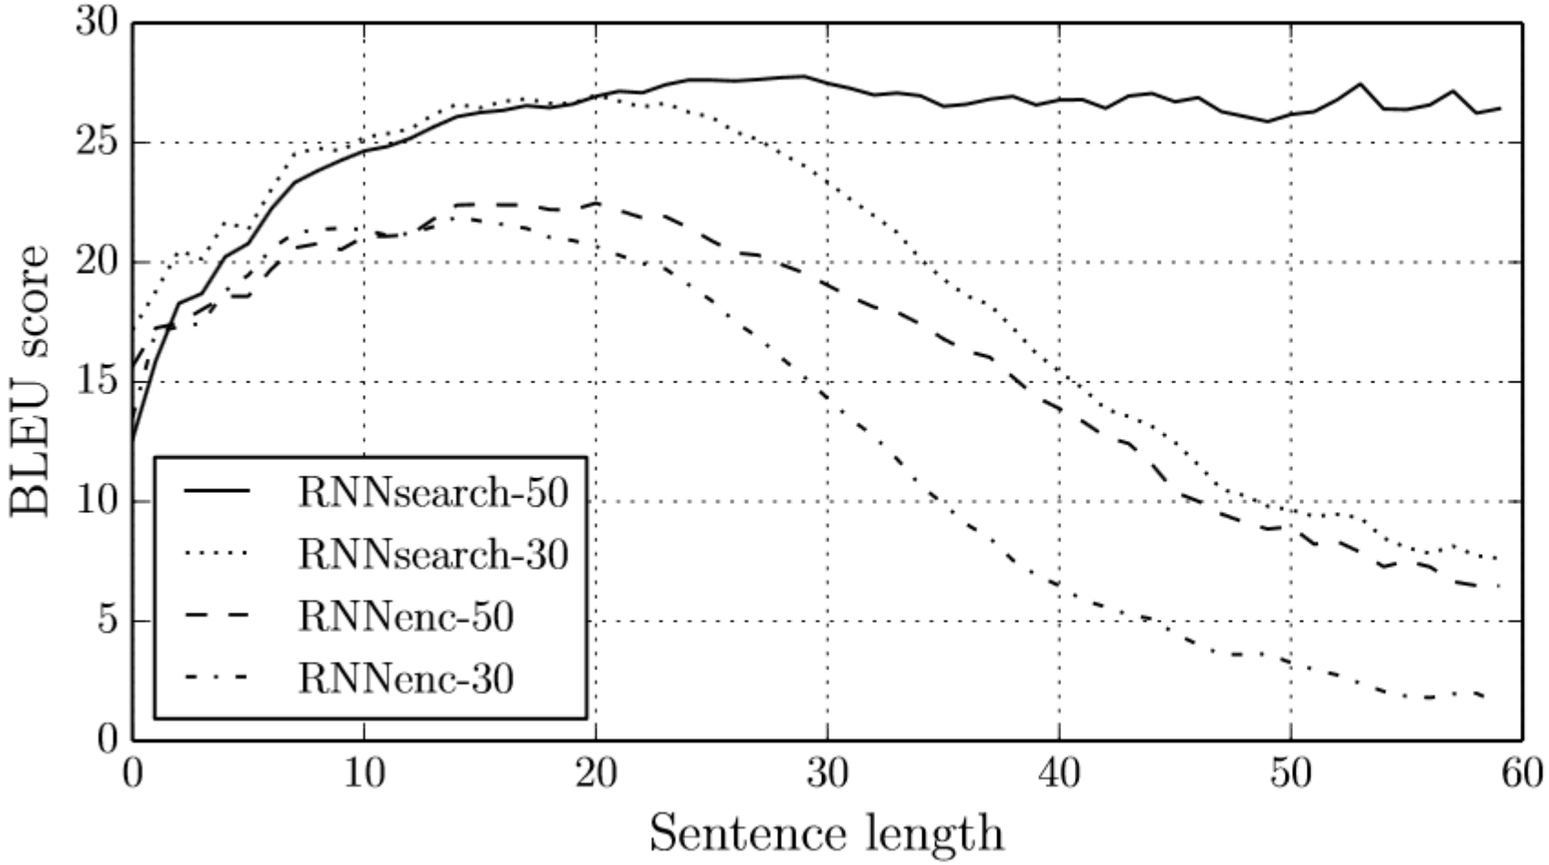

Figure 2: The BLEU scores of the generated translations on the test set with respect to the lengths of the sentences. The results are on the full test set which includes sentences having unknown words to the models.

seq2seq vs attention

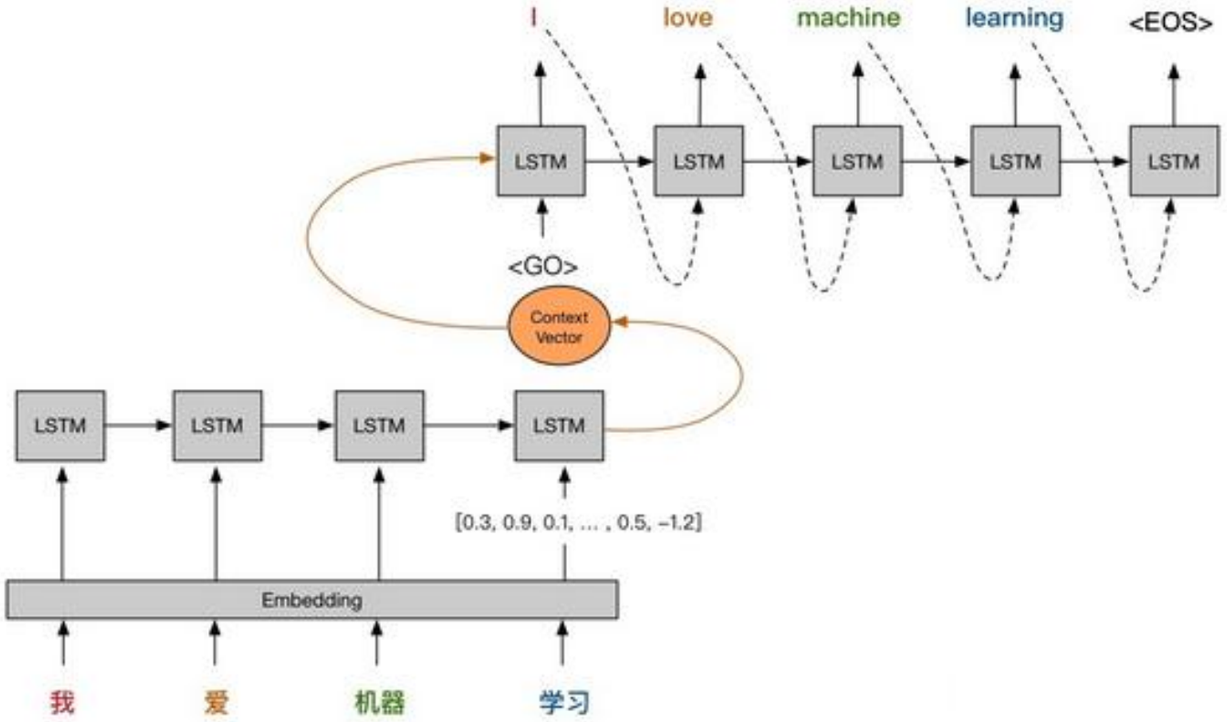

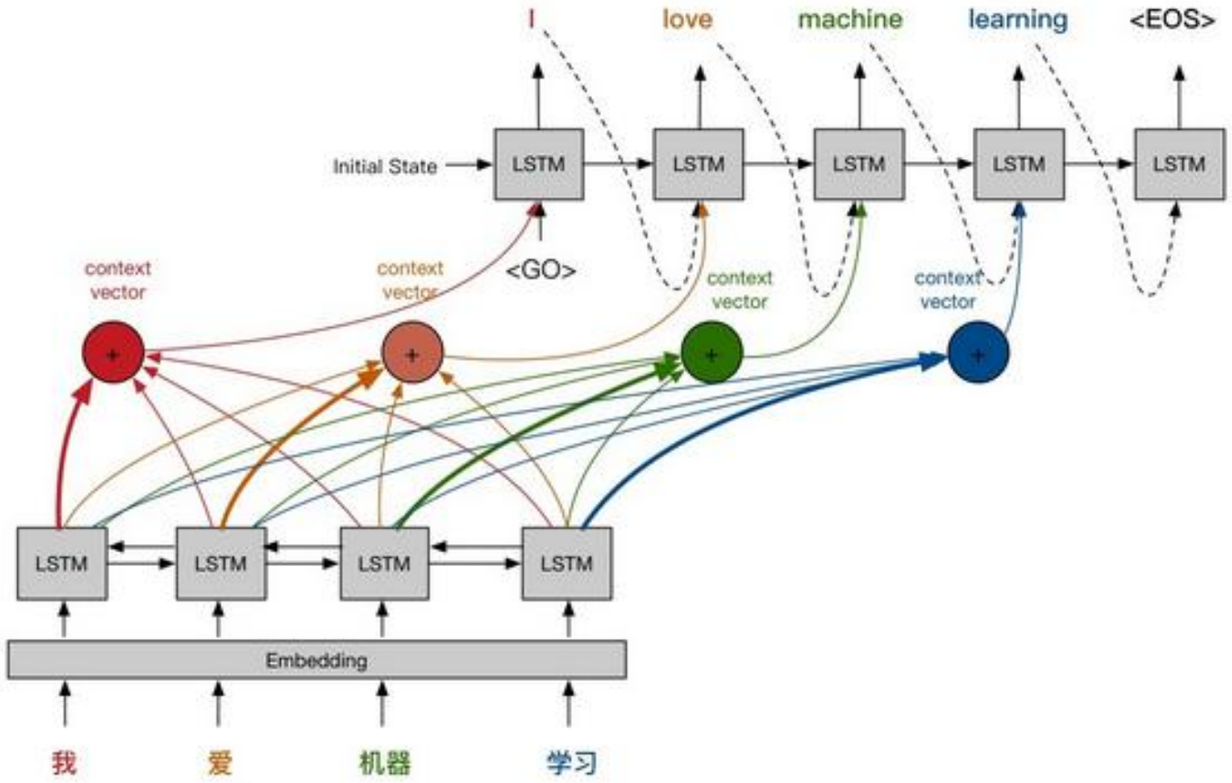

Внимание – техника вычисления взвешенной суммы значений (values) по запросу (query)

~ техника получения описания (representation) фиксированного размера по запросу

https://zhuanlan.zhihu.com/p/37290775

Плюсы механизма внимания (Attention)

- улучшает качество перевода (и не только)
- решает проблему «узкого горла»
- появляется интерпретируемость
- решает проблему «затухания сигнала» / исчезающего градиента
- получаем выравнивание (alignment) «бесплатно» в переводе

Виды внимания

Self-Attention / intra-attention	к разным позициям одной и той же входной последовательности
Global / Soft	ко всему входу
Local / Hard	к части входа

http://proceedings.mlr.press/v37/xuc15.pdf

Виды внимания: Self-Attention

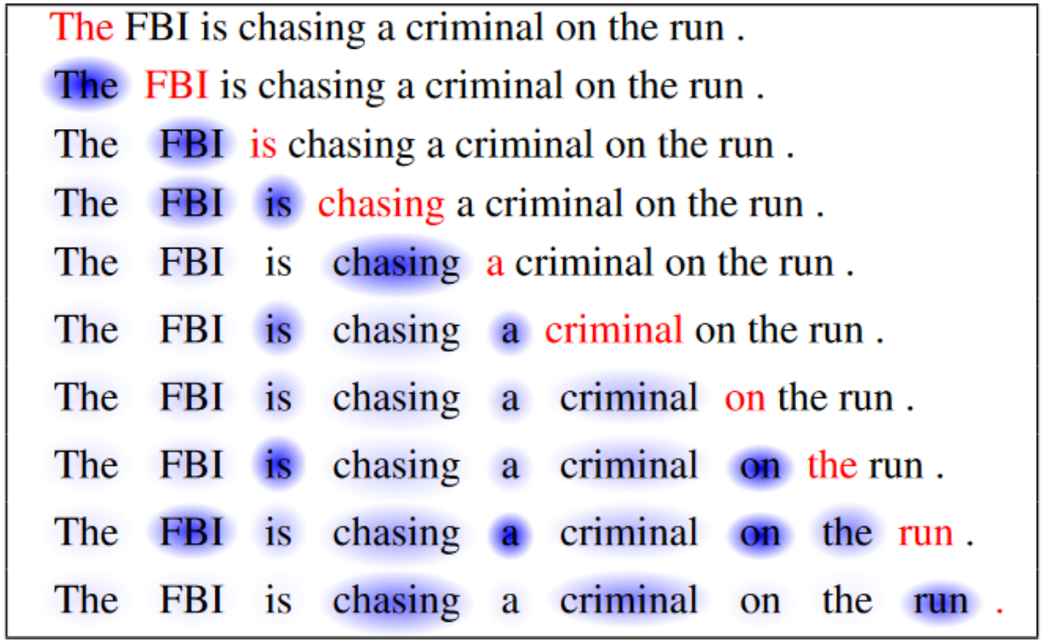

Figure 1: Illustration of our model while reading the sentence *The FBI is chasing a criminal on the run.* Color *red* represents the current word being fixated, *blue* represents memories. Shading indicates the degree of memory activation.

Там НС, которая читает и сохраняет в память (детали сейчас не важны) главное – на что она смотрит при чтении конкретного слова

https://arxiv.org/pdf/1601.06733.pdf

Виды внимания: Global vs Local Attention

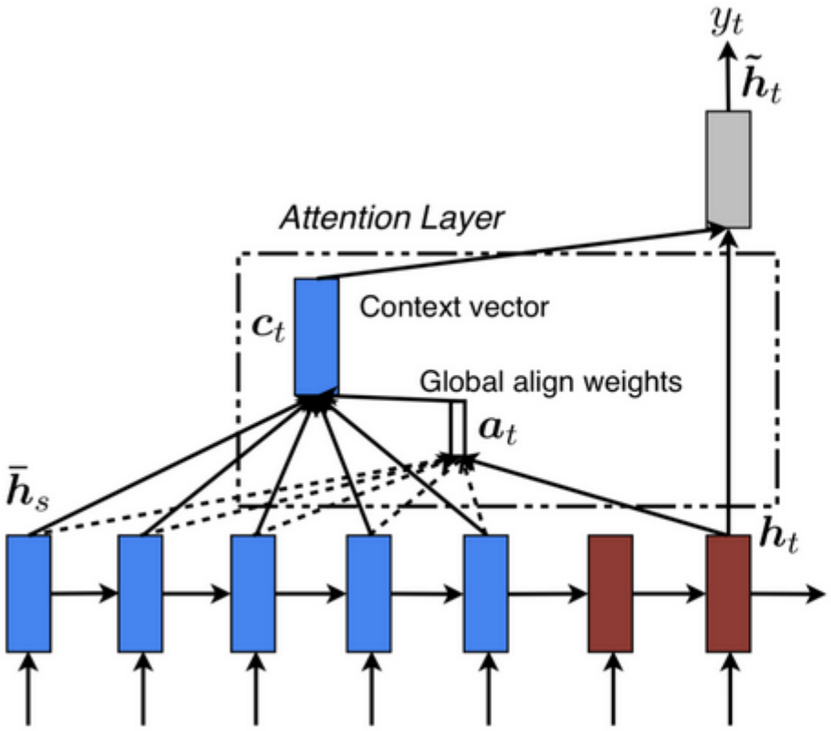

Global Attention Model

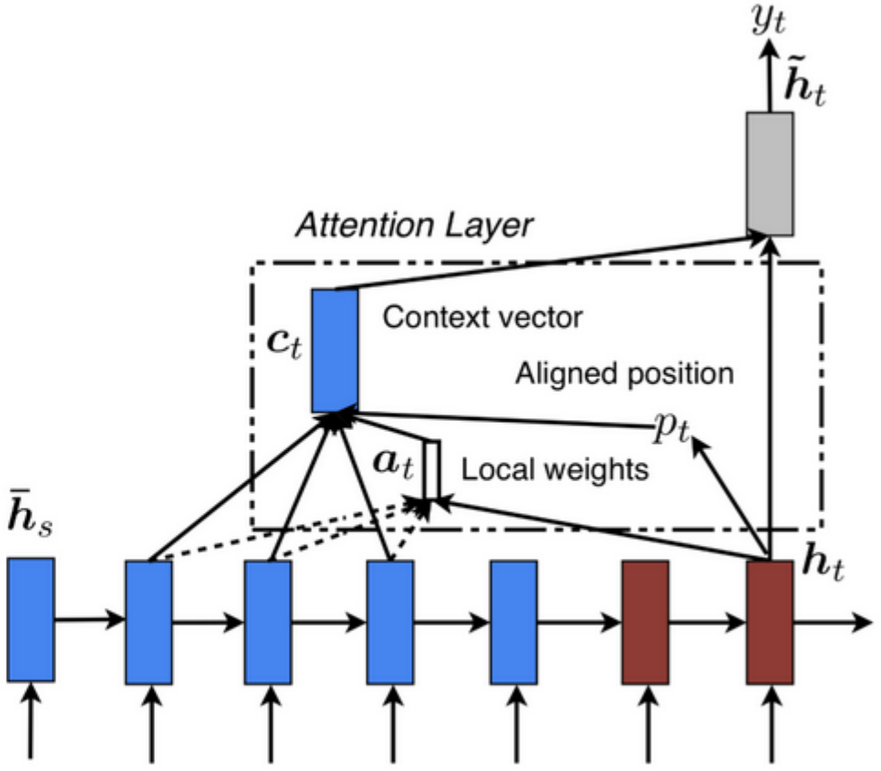

Local Attention Model

https://lilianweng.github.io/lil-log/2018/06/24/attention-attention.html#born-for-translation

Виды внимания

Convolution

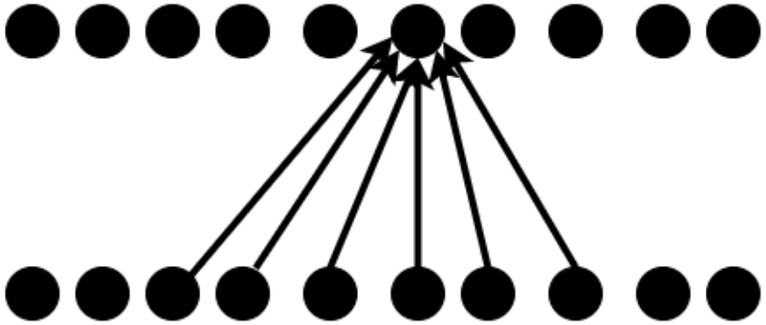

Global attention

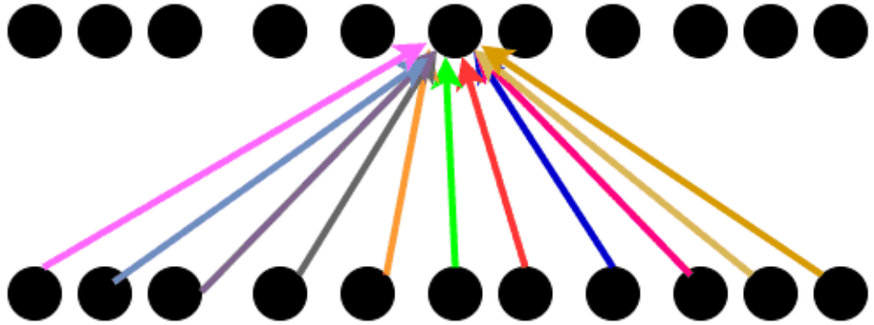

Fully Connected layer

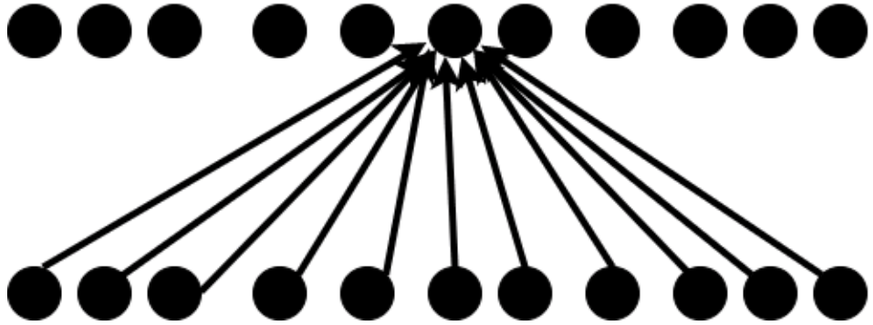

Local attention

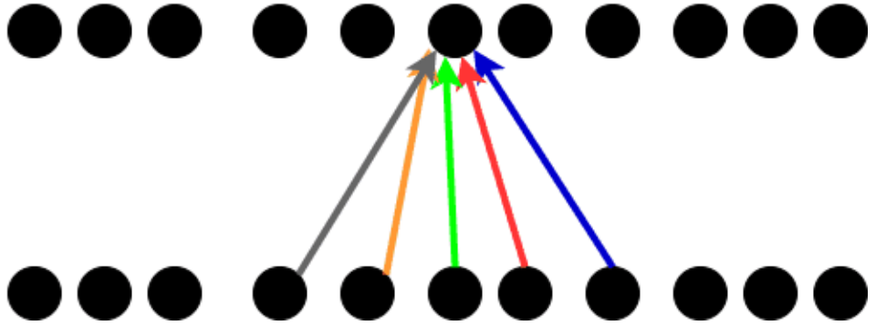

https://theaisummer.com/attention/

Самовнимания (self-attention) – будет дальше

Self-attention
Probability score matrix

	Hello	I	love	you
Hello	0.8	0.1	0.05	0.05
I	0.1	0.6	0.2	0.1
love	0.05	0.2	0.65	0.1
you	0.2	0.1	0.1	0.6

Softmax(Attention)
equation

Self-attention as a
undirected weighted graph

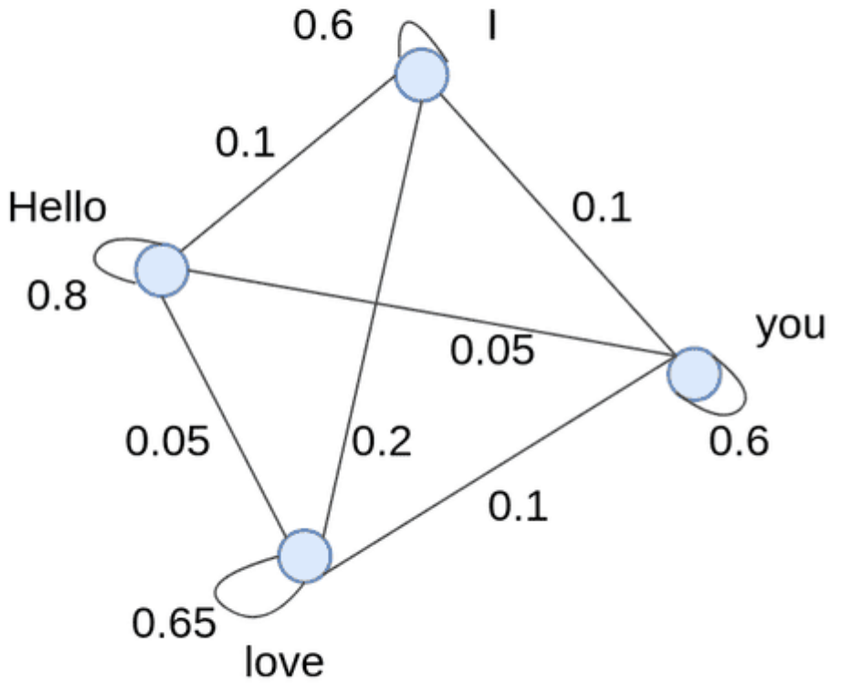

https://theaisummer.com/attention/

Итог

свёрточные сети – не только для изображений
можно CNN + RNN

seq2seq – простоя и понятная архитектура

внимание – на что «смотрим»
коэффициенты специально считаются

Есть разные виды внимания

Ссылки

Обзор про внимание

https://lilianweng.github.io/lil-log/2018/06/24/attention-attention.html

Итог

RNN

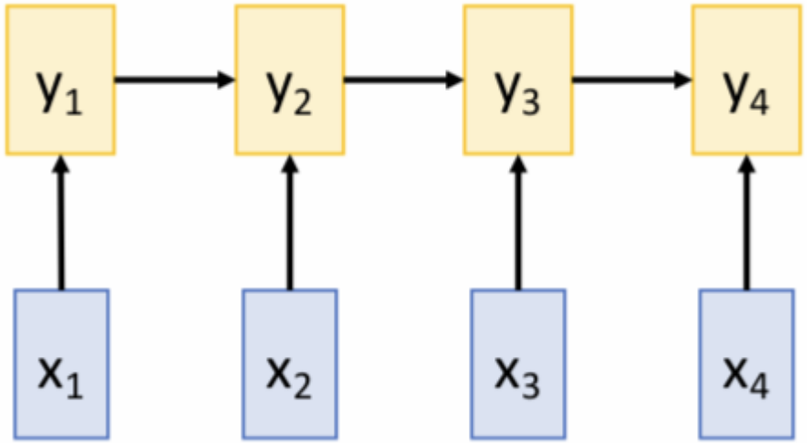

+

естественная архитектура

хорошо для коротких посл-ей

–

не распараллеливается

1D Conv

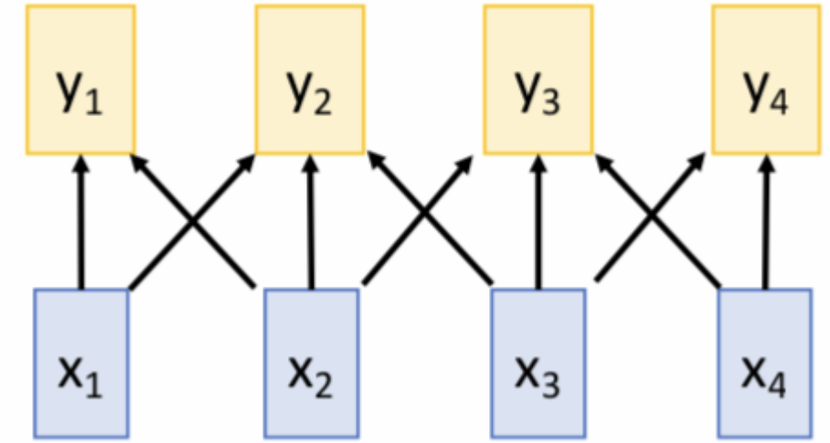

+

распараллеливается

–

плохо для длинных посл-ей

Self-Attention

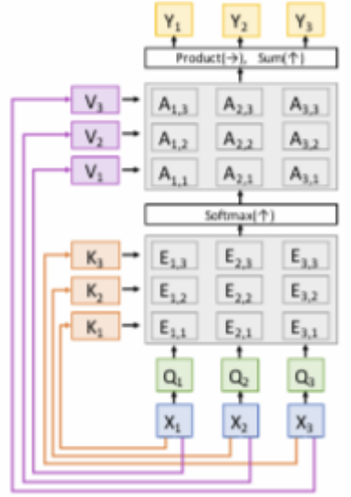

+

хорошо для длинных посл-ей

можно распараллелить

–

затратно по памяти

будет подробнее

[Justin Johnson]